

**SZEGEDI TUDOMÁNYEGYETEM
INFORMATIKAI INTÉZET**

SZAKDOLGOZAT

**Giricz Vince
2026**

SZEGEDI TUDOMÁNYEGYETEM INFORMATIKAI INTÉZET

Multidimenzionális idősorok előfeldolgozása és osztályozása deep learning alapú
megközelítésekkel

SZAKDOLGOZAT

Készítette:

Giricz Vince

Programtervező Informatikus alapszak

Témavezető:

Dr. habil. Jász Judit

Egyetemi adjunktus

Szeged, 2026

Feladatkiírás

Az idősor adatok feldolgozása és elemzése egyre nagyobb jelentőséggel bír a modern informatika számos területén, mint például az egészségügyi adatok - például EKG, GSR, pulzus - pénzügyi idősorok, vagy IoT eszközök által rögzített adatok elemzésében. Az idősorok osztályozása különösen nagy kihívást jelent, mivel az adatok jellemzői időben változnak, gyakran párhuzamosan több forrásból származnak, multidimenzionális szerkezetűek, ezek miatt hagyományos módszerekkel gyakran nehezen elemezhetőek.

A deep learning technológiák, különösen az embedding alapú reprezentációk lehetőséget adnak arra, hogy az idősorokból automatikusan kinyerhető jellemzők segítségével pontosabb osztályozás valósuljon meg.

A vázolt kutatási feladat egy tetszőlegesen választott, szakirodalomban elérhető multidimenzionális idősor vizsgálatának megvalósítása, amelyben a hallgató megvizsgálja, hogy az adathalmaz embedding technikákkal (pl. MOMENT eszköz által) történő konvertálása milyen gyakorlati problémákat vet fel, ezeket hogyan lehet kezelni, illetve végső soron milyen klaszterezési eredmény várható el az így megadott adatok feldolgozása által különböző gépi tanulási modellek segítségével.

Fontos, hogy a hallgató a tapasztalatait a dolgozatban úgy rögzítse, hogy azok tanulsága, illetve maga a folyamat könnyen adaptálható legyen tetszőleges multisoros adathalmazok klaszterezésére is.

Tartalmi összefoglaló

- **A téma megnevezése:**

Multidimenzionális idősorok előfeldolgozása és osztályozása deep learning alapú megközelítésekkel.

- **A megadott feladat megfogalmazása:**

A kutatás feladata a MOMENT idősoros alapmodell által generált beágyazások elemzése és felügyelet nélküli klaszterezése, összevetve a hagyományos gépi tanulási és a mély neurális hálózatokat alkalmazó algoritmusok teljesítményét. További cél az adatalapú modellezés során fellépő osztály-kiegyensúlyozatlanság problémájának kezelése és hatásainak vizsgálata a PTB-XL klinikai adathalmazon.

- **A megoldási mód:**

A klinikai adatokra jellemző statisztikai torzítások elkerülése érdekében az adatokon először osztályszintű kiegyensúlyozást hajtottam végre. A MOMENT az 1024 dimenziós sűrű jellemzőteret dimenziócsökkentő eljárásokkal csökkentettem, és hagyományos távolság- és sűrűségalapú, illetve valószínűségi és mesterséges neurális hálózatokra épülő mélytanulósos architektúrákkal vizsgáltam, és értékeltem ki a klaszterek elkülöníthetőségét.

- **Alkalmazott eszközök, módszerek:**

A fejlesztést Python nyelven, a PyTorch és Scikit-learn gépi tanulási könyvtárak felhasználásával történt. Az idősorok reprezentációinak előállítására a MOMENT alapmodellt használtam. Alkalmazott algoritmusok: PCA, UMAP, K-Means, DBSCAN, GMM, valamint Deep Embedded Clustering (DEC) és Improved Deep Embedded Clustering (IDEC) architektúrák.

- **Elért eredmények:**

A kísérletek rávilágítottak arra, hogy az alapmodell által kinyert EKG-reprezentáció geometriailag rendkívül komplex. A vizsgált felügyelet nélküli algoritmusok közül a valószínűségi (GMM) és a hiperparaméter-hangolt mély klaszterező (IDEC) modell érte el a legjobb, megközelítőleg 38%-os pontossági eredményt. A kutatás legfőbb tanulsága, hogy ez a pontossági plafon nem algoritmikus hiányosság, hanem a biológiai adatok természetét: a klinikai kategóriák (betegségek) közötti éles határok hiányát és folytonosságát tükrözi, ezért az adatok tiszta felügyelet nélküli tanulási módszerekkel rendkívül nehezen szeparálhatók.

- **Kulcsszavak:**

EKG jelfeldolgozás, előfeldolgozás, PTB-XL, alapmodellek, MOMENT, felügyelet nélküli tanulás, klaszterezés, mélytanulás, DEC, IDEC.

Tartalomjegyzék

Feladatkiírás	2
Tartalmi összefoglaló	3
Tartalomjegyzék.....	4
BEVEZETÉS	6
1. SZAKIRODALMI ÁTTEKINTÉS ÉS ELMÉLETI HÁTTÉR.....	7
1.1. A PTB-XL adathalmaz bemutatása (multidimenzionális idősorok).....	7
1.2. Idősorok reprezentáció tanulása: A MOMENT alapmodell bemutatása.....	8
1.3. Klaszterezési és felügyelet nélküli osztályozási eljárások	9
1.4. A klaszterezési eredmények kiértékelési metrikái.....	10
1.5. Deep Learning alapú klaszterezés: DEC, IDEC bemutatása	11
2. MÓDSZERTAN ÉS SAJÁT MUNKA.....	13
2.1. Hardveres és szoftveres környezet.....	13
2.1.1. Hardveres erőforrás	13
2.1.2. Szoftveres platform és fejlesztői környezet	13
2.1.3. Főbb felhasznált python könyvtárak.....	14
2.2. Adatelőkészítés és tisztítás a PTB-XL-en	15
2.2.1. A metaadatok feldolgozása és szűrése.....	15
2.2.2. Az EKG jelek feldolgozása és dimenziói	16
2.2.3. Interpoláció és egységesítés	17
2.3. Jellemzőkinyerés a MOMENT modellel (embeddingek generálása).....	17
2.3.1. A MOMENT alapmodell elméleti háttére és működése	18
2.3.2. A bemeneti adatok standardizálása és tenzorral alakítása	19
2.3.3. A modell inicializálása és az input maszkolás.....	19
2.3.4. Az inferencia folyamata és a memóriakezelés.....	20
2.4. Felügyelet nélküli osztályozási kísérletek és adatrepresentáció validálása	21
2.4.1. Alapvonal (Baseline) kísérlet: K-Means klaszterezés	22
2.4.2. A MOMENT beágyazások validálása felügyelt tanúlással	22
2.4.3. Sűrűségalapú megközelítés	23
2.4.4. Kiegyensúlyozott adathalmaz és optimalizálási keretrendszer	24
2.4.5. HDBSCAN + UMAP és GMM + PCA implementációja a keretrendszerben.....	26
2.5. Mélytanulás alapú klaszterezés (Deep Clustering).....	28
2.5.1. Adatelőkészítés és az Autoencoder felépítése	28
2.5.2. A DEC és IDEC modellek implementációja és architektúrája	29
2.5.3. A hálózatok hiperparaméterei és a tanítási folyamat	29
3. EREDMÉNYEK ÉS KIÉRTÉKELÉS.....	30
3.1. A hagyományos modellek eredményei	31
3.1.1. A MOMENT beágyazások validálása felügyelt tanúlással	31

3.1.2. A távolságalapú klaszterezés korlátai (K-Means alapvonal)	33
3.1.3. Fejlett klaszterezési eljárások optimalizálása	35
3.2. DEC és IDEC modellek eredményei.....	37
3.3. A legeredményesebb modellek összehasonlítása.....	39
4. ÖSSZEFOGLALÁS	40
4.1. A MOMENT alapmodell alkalmazhatósága az EKG-diagnosztikában	40
4.2. A felügyelet nélküli algoritmusok korlátai és a klinikai adatok természete.....	40
4.3. Jövőbeli kutatási irányok és fejlesztési lehetőségek.....	41
Irodalomjegyzék.....	42
Köszönetnyilvánítás	45

BEVEZETÉS

Az orvosi idősorok automatikus osztályozása napjainkban kiemelt kutatási terület, hiszen a különféle betegségek gépi úton történő azonosítása lehetővé tenné a diagnózis automatikus detektálását kizárólag a rögzített adatok alapján. Szakdolgozatomban a PTB-XL adathalmazt használok fel az előfeldolgozási lépések, a beágyazások legenerálása, valamint a különböző osztályozó algoritmusok kiértékelése során. Ez a multidimenzionális adathalmaz 12 élvezetéssel rögzített elektrokardiogram (EKG) jelet tartalmaz, amelyek kétféle mintavételezési gyakorisággal (100hz és 500hz) érhetők el, egységesen 10 másodpercnyi rögzítési hosszal, amelyből én a sűrűbben mintavételezett változatot használtam fel.

Az automatikus osztályozási folyamat megvalósítása során alapvetően két nehézséggel kell szembenéznünk. Az első az adatok egységes reprezentációra való hozása. Ezt a problémát modern jellemzőkinyerő modell/ beágyazásai eljárás alkalmazásával hidalhatjuk át, amelyek képesek az idősorokból tömör és jól felhasználható jellemzővektorokat megtanulni. A második és komplexebb feladat maga az osztályozás. Annak érdekében, hogy a folyamat teljesen automatizált legyen, felügyelet nélküli (unsupervised) osztályozó eljárásra van szükség. Ebben az esetben az osztályozó nem rendelkezik előzetes információval az adatok osztálycímkeiről. A feladata, hogy a beágyazási vektorok adott térben elfoglalt geometriai elhelyezkedése alapján azonosítsa a csoportokat. Ez a megközelítés akkor eredményes, ha a beágyazási modell megfelelően kódolja az idősorok releváns információit, és a mérések között nincs nagymértékű átfedés.

A felügyelet nélküli eljárások alkalmazása során visszatérő probléma az adatok közötti jelentős átfedés és tiszta, jól elkülöníthető klaszterek hiánya. A felügyelt (supervised) tanulási módszerek azonban igazolták, hogy az adathalmaz elméletben jól szerparálható az öt főosztályba, és a MOMENT alapmodell beágyazásai is megőrizték a rögzítések fontos információit, ám a felügyelet nélküli modelleknél rendszeresen tapasztalható, hogy az adatok a beágyazási térben nem különülnek el megfelelően. Emiatt a tisztán geometriai alapokon működő klaszterező eljárások gyakran nem képesek kielégítő pontossággal megtalálni a keresett osztályokat.

Dolgozatom elsődleges célja a MOMENT alapmodell segítségével létrehozott közös reprezentáció vizsgálata, és a különböző osztályozó és klaszterező eljárások összevetése. A kutatás során a hagyományos statisztikai modellek mellett a mélytanulás alapú megközelítések teljesítményét is elemzem.

A dolgozatom szerkezete

A munka további részében - az első fejezetben - az elméleti háttérrel, és a PTB-XL adathalmaz mutatom be. A második fejezetben részletezem a saját munkámat, beleértve az adatok előfeldolgozását, a MOMENT modellel való jellemzőkinyerést és a kísérleti beállításokat. A harmadik fejezetben ismertetem a hagyományos, és mélytanulás alapú modellekkel elért eredményeket, végül az összefoglalásban kitérek a modellek alkalmazhatóságára és a levont következtetésekre.

1. Szakirodalmi áttekintés és elméleti háttér

A jelen fejezet célja, hogy megalapozza a kutatás során alkalmazott módszertani és technológiai megoldások elméleti hátterét, valamint áttekintse a vizsgált problémakörhöz kapcsolódó nemzetközi szakirodalmat. A modern kardiovaszkuláris diagnosztikában a gépi tanulási és mesterséges intelligencia modellek alkalmazása egyre nagyobb hangsúlyt kap, azonban a komplex, többcsatornás fiziológiai jelek feldolgozása komoly adatelemzési kihívásokat támaszt.

A fejezet első felében bemutatásra kerül az orvosi idősorok strukturális felépítése a PTB-XL klinikai adathalmaz példáján keresztül, majd áttekintésre kerülnek az idősoros adatok reprezentációtanulásának legújabb irányvonalai, különös tekintettel az alapmodellekre (*foundation models*) és a transzformer-alapú MOMENT architektúrára. Ezt követően a felügyelet nélküli tanulás elméleti koncepciói következnek, megvizsgálva a klasszikus távolság-, sűrűség- és valószínűség-alapú klaszterező algoritmusok (K-Means, HDBSCAN, GMM) matematikai működését és elméleti korlátait a magas dimenziós terekben. Végül a fejezet a legkorszerűbb, mélytanulás-alapú klaszterezési paradigmák (DEC és IDEC) működési elvének bemutatásával zárul, megteremtve ezzel az elméleti alapot a dolgozat későbbi kísérleteihez.

1.1. A PTB-XL adathalmaz bemutatása (multidimenzionális idősorok)

A kardiovaszkuláris megbetegedések automatizált diagnosztikájában és a gépi tanulási modellek fejlesztésében az egyik legjelentősebb áttörést a nyilvánosan elérhető, nagyméretű klinikai adathalmazok megjelenése jelentette. Ezen a területen jelenleg az egyik legfontosabb, nemzetközileg széles körben elismert referenciapont a PTB-XL elektrokardiográfiai (EKG) adathalmaz, amelyet Wagner és munkatársai publikáltak 2020-ban [1].

Az EKG felvételek matematikai és informatikai szempontból komplex, multidimenzionális (többváltozós) idősoroknak tekinthetők. A PTB-XL adathalmaz egyik fő jellegzetessége, hogy minden egyes rekord a standard klinikai 12 elvezetést (I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6) tartalmazza. Ezek a csatornák egyidejűleg, de eltérő geometriai vetületekből regisztrálják a szívizomzat elektromos aktivitását, így a biomedicinális jelfeldolgozás során nem csupán a csatornákon belüli időbeli függőségeket, hanem az elvezetések közötti térbeli korrelációkat is elengedhetetlen figyelembe venni.

A PTB-XL adathalmaz másik kiemelkedő értéke a magas szintű, strukturált orvosi annotáció. Az eredeti publikáció és a vonatkozó irodalmi ajánlások alapján a rekordok öt diagnosztikai főosztályba (diagnostic superclasses) sorolhatók, amelyek a következők:

1. **NORM (Normal):** Egészséges, patológiás elváltozást nem mutató EKG felvételek.
2. **MI (Myocardial Infarction):** Miokardiális infarktus (szívizomelhalás) jeleit mutató mérések.
3. **STTC (ST/T Changes):** Az ST-szakasz vagy a T-hullám nem-specifikus morfológiai elváltozásai.
4. **CD (Conduction Disturbance):** Különböző szívbelüli vezetési zavarok és blokkok.

5. **HYP (Hypertrophy):** Szívizom-túltengésre vagy kamra-hipertrófiára utaló jelek.

Az adathalmaz elméleti sajátossága, és egyben a gépi tanulási modellek szempontjából kritikus tényező a jelentős osztály-kiegyensúlyozatlanság. Míg a normál esetek (NORM) statisztikailag dominálják az állományt, addig az olyan specifikus patológiák, mint a hipertrófia (HYP), csak lényegesen kisebb esetszámban fordulnak elő. A vonatkozó szakirodalom rámutat arra, hogy ez a strukturális egyenetlenség komoly torzító tényezőt jelent a hagyományos felügyelet nélküli algoritmusok számára. Ennek oka, hogy az adatalapú modellek hajlamosak a statisztikai dominanciára építve a kisebbségi osztályokat pusztán zajként elvetni vagy egybemosni a többségi osztállyal. Ez a sajátosság teszi elméletileg is indokolttá a modellépítést megelőző célzott adat-előkészítési és mintavételezési stratégiák alkalmazását.

1.2. Idősorok reprezentáció tanulása: A MOMENT alapmodell bemutatása

A hagyományos idősor-elemzési és osztályozási módszerek jelentős része manuálisan tervezett jellemzőkre, statisztikai mutatókra vagy közvetlen időbeli távolságmértékekre támaszkodik. Bár ezek a megközelítések egyszerűbb feladatok esetén hatékonyak, a modern orvosi diagnosztikában keletkező nagy dimenziójú, többcsatornás és zajos idősorok – mint amilyenek a komplex, 12 elvezetéses EKG-jelek is – elemzése során komoly skálázódási és számításkapacitási korlátokba ütköznek. Ezen korlátok feloldására született meg az idősorok felügyelet nélküli reprezentációtanulása (*time-series representation learning*), amelynek célja, hogy a komplex, nyers idősoros adatokat egy sűrű, rögzített dimenziójú látens térbe (beágyazási térbe/ *embedding space*) képezze le úgy, hogy az adatokban rejlő szemantikai és strukturális információk megőrződjenek.

A természetesnyelv-feldolgozás (NLP) és a számítógépes látás (CV) területén elért sikerek mintájára az idősor-analízisben is megjelentek az úgynevezett alapmodellek (*foundation models*). Ezek a nagyméretű, többnyire transzformer architektúrára épülő modellek hatalmas mennyiségű, változatos forrásból származó adaton mennek keresztül egy felügyelet nélküli előtanítási (*pre-training*) fázison. Az előtanítás során a modell megtanulja az adatok univerzális és robusztus jellemzőit, így a keletkező reprezentációk (beágyazások) közvetlenül vagy minimális finomhangolással alkalmazhatók különböző downstream feladatokban, mint például az osztályozás, az anomália-detektálás vagy a felügyelet nélküli klaszterezés.

A többváltozós idősorok felügyelet nélküli elemzésének egyik legújabb, élvonalbeli eszköze a Goswami és munkatársai által 2024-ben bemutatott MOMENT modellelcsalád [2]. A MOMENT az első olyan nyílt forráskódú idősor-alapmodell, amelyet kifejezetten arra terveztek, hogy univerzális reprezentációt biztosítson rendkívül heterogén idősoros adatokhoz, függetlenül azok mintavételezési gyakoriságától, hosszától vagy a csatornák számától.

A MOMENT modell elméleti alapját a Vaswani és munkatársai által leírt Transformer architektúra [3] képezi, azon belül is a kódoló (*Encoder*) blokkok sorozata. Mivel az idősorok pontonkénti feldolgozása rendkívül számításigényes és érzékeny a lokális zajokra, a MOMENT a számítógépes látásban elterjedt *Vision Transformer* (ViT) logikáját követi: a bemeneti idősort egymást át nem fedő, rögzített hosszúságú szakaszokra, úgynevezett foltokra (*patches*) bontja

fel. Ezeket a foltokat a modell lineáris projekcióval egy magasabb dimenziós térbe vetíti, majd pozicionális kódolással (*positional encoding*) látja el, hogy megőrizze az időbeli sorrendiséget.

A transzformátor kódolóban működő többfejes ön-figyelmi (*multi-head self-attention*) mechanizmus lehetővé teszi, hogy a modell feltárja az idősor távoli pontjai, valamint a többszörös rendszerek esetén a csatornák közötti komplex, térbeli és időbeli nemlineáris összefüggéseket. A MOMENT előtanítása egy speciális felügyelet nélküli feladat, a maszkolt idősor-modellezés (*masked time-series modeling*) segítségével történik. Ennek során a bemeneti foltok egy részét véletlenszerűen elfedik (maszkolják), és a hálózatnak a megmaradt kontextus alapján rekonstruálnia kell a hiányzó részeket. Ez arra készíti a modellt, hogy mély megértést fejlesszen ki az idősorok belső dinamikájáról, trendjeiről és periodikus jellemzőiről.

Az előtanított MOMENT kódoló utolsó rétegének kimenete reprezentálja a teljes idősort egy sűrű, fix méretű jellemzővektorként (például 1024 dimenzióban). Az elméleti háttér szempontjából kiemelő, hogy ez a geometriai tér már nem az időbeli amplitúdók nyers sorozata, hanem egy olyan absztrakt leképezés, ahol a hasonló fiziológiai vagy morfológiai tulajdonságokkal rendelkező idősorok elméletileg közelebb helyezkednek el egymáshoz, megalapozva ezzel a felügyelet nélküli klaszterezési eljárások alkalmazhatóságát.

1.3. Klaszterezési és felügyelet nélküli osztályozási eljárások

A felügyelet nélküli tanulás (unsupervised learning) egyik legfontosabb ága a klaszterezés, amelynek célja, hogy az adathalmaz elemeit előzetesen megadott címkék hiányában, pusztán a belső hasonlóságai és távolságviszonyai alapján rendezze homogén csoportokba. A magas dimenziós jellemzőterek – mint amelyeket a modern reprezentációtanuló modellek is előállítanak – elemzése során a gépi tanulási algoritmusok egy ismert matematikai jelenséggel, a „dimenziók átkával” (*curse of dimensionality*) szembesülnek. A szakirodalom rámutat, hogy ahogy a tér dimenziószáma növekszik, az adatpontok közötti euklideszi távolságok különbsége minimálisra csökken, aminek következtében a hagyományos távolságmértékek elveszítik diszkriminációs erejüket.

Ennek a problémának a kezelésére az adatelemzési folyamatok gyakran alkalmaznak nemlineáris dimenziócsökkentő eljárásokat. Az egyik legkorszerűbb ilyen módszer a sokaságtanuláson (*manifold learning*) és topológiai adatelemzésen alapuló UMAP (*Uniform Manifold Approximation and Projection*) [4]. Az algoritmus előnye a klasszikus lineáris eljárásokkal (például a PCA-val) szemben, hogy a dimenziócsökkentés során nemcsak az adatok lokális szomszédsági viszonyait, hanem a halmaz globális struktúráját is képes nagy pontossággal megőrizni egy alacsonyabb dimenziós térben.

A dimenziócsökkentett, vagy az eredeti teret vizsgálva a klaszterezési feladatokra alapvetően három fő elméleti megközelítést alkalmaz a szakirodalom:

Távolságalapú klaszterezés (K-Means): A K-Means [5] a legszélesebb körben alkalmazott távolságalapú particionáló algoritmus, amely az adathalmazt K darab klaszterre osztja fel úgy, hogy minimalizálja az adatpontok és a hozzájuk tartozó klaszterközéppontok (centroidok) közötti négyzetes távolságok összegét. Bár számítási igénye alacsony, az algoritmus alapvető geometriai korlátja, hogy csak gömbszimmetrikus, azonos sűrűségű és méretű klasztereket

feltételez. Komplex, egymásba lógó vagy nemlineáris eloszlású adatok esetén a K-Means gyakran alulteljesít.

Sűrűségalapú klaszterezés (DBSCAN és HDBSCAN): A geometriai megkötések feloldására az Ester és munkatársai által bevezetett DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) [6] algoritmus nyújtott elméleti alternatívát. A DBSCAN a klasztereket a tér összefüggő, magas sűrűségű régióiként definiálja, amelyeket alacsony sűrűségű területek választanak el egymástól. Ez a megközelítés lehetővé teszi tetszőleges formájú klaszterek felismerését, és képes a ritkás régiókban lévő pontokat zajként (kiugró értéként) azonosítani. A hagyományos DBSCAN hátránya azonban az, hogy rendkívül érzékeny a globális sűrűségi paraméter (eps) megválasztására. Ezt a problémát hivatott orvosolni a továbbfejlesztett HDBSCAN (*Hierarchical DBSCAN*) [7], amely hierarchikus sűrűségbecslést végez. A HDBSCAN képes a változó sűrűségű klaszterek robusztus azonosítására anélkül, hogy egyetlen merev távolsági küszöbértéket követelne meg, így jóval stabilabb eredményeket biztosít a heterogén adathalmazokon.

Valószínűségi modellezés (GMM): A merev határokat húzó (*hard clustering*) algoritmusokkal szemben a Gauss-keverék modellek (Gaussian Mixture Models, GMM) a lágy klaszterezés (*soft clustering*) paradigmáját követik. A GMM azt feltételezi, hogy az adathalmaz több, eltérő paraméterekkel rendelkező normál eloszlás keverékéből származik. Az algoritmus az Expectation-Maximization (EM) módszerrel iteratíván illeszti az eloszlásokat az adatokra, így képes elnyújtott, elliptikus klaszterek modellezésére is. Ennek eredményeként nem egyetlen kategóriába kényszeríti a pontokat, hanem valószínűségeket rendel azokhoz, ami különösen előnyös a határeseteket (szürke zónákat) tartalmazó adathalmazoknál.

Hiperparaméter-optimalizálás és az osztály-kiegyensúlyozatlanság problémája: A felügyelet nélküli eljárások sikere nagyban függ a megfelelő hiperparaméterek (például a szomszédok száma, minimális klaszterméret) megválasztásától. A modern gépi tanulásban ennek automatizálására fejlett keretrendszereket alkalmaznak, mint amilyen az Optuna [8], amely bayesi optimalizációs stratégiák (például a Tree-structured Parzen Estimator, TPE) révén hatékonyan kutatja fel az optimális paraméterteret.

Ugyanakkor a szakirodalom egyöntetűen felhívja a figyelmet egy kritikus problémára: az adathalmazok osztály-kiegyensúlyozatlansága (*class imbalance*) súlyosan torzíthatja a felügyelet nélküli modellek eredményeit. Kiegyenlítetlen eloszlások esetén a sűrűség- és távolság alapú algoritmusok hajlamosak a többségi osztályokat egyetlen domináns klaszterbe olvasztani, miközben a ritkább eseteket (kisebbségi osztályokat) különálló eloszlások helyett egyszerű statisztikai zajként vagy anomáliaként vetik el [1]. A reprezentációk hiteles kiértékeléséhez ezért az elméleti keretrendszerek gyakran megkövetelik a mintavételezési arányok kiegyenlítését.

1.4. A klaszterezési eredmények kiértékelési metrikái

A felügyelet nélküli gépi tanulási kísérletek eredményeinek objektív összehasonlításához olyan matematikai metrikákat alkalmaztam, amelyek képesek számszerűsíteni a kapott klaszterstruktúrák jóságát. A kiértékelés során belső (valós címkéket nem igénylő) és külső (a

valós diagnózisokat alapul vevő) mutatókra egyaránt támaszkodtam, a szoftveres környezetet biztosító Scikit-learn dokumentációja alapján.

Elsőként a klaszterek sűrűségét és elkülönülését vizsgáló Silhouette-együtthatót (Silhouette Score) alkalmaztam [9]. Ez a metrika azt méri, hogy egy adott adatpont mennyire hasonlít a saját klaszterébe tartozó többi ponthoz (kohézió), összehasonlítva a legközelebbi szomszédos klaszter pontjaival (szeparáció). Értéke -1 és +1 között mozog: a +1 közeli érték jól elkülönült, sűrű klasztereket jelez, a 0 körüli érték egymásra lógó csoportokra utal, míg a negatív értékek azt mutatják, hogy a pontok rossz klaszterbe kerültek. Mivel ehhez nem kellenek a valós címkék, ez a mutató magát a geometriai szerkezetet értékeli.

A külső validációhoz – vagyis a megtalált klaszterek és a megtartott valós diagnosztikai főosztályok összevetéséhez – a Korrigált Rand-indexet (Adjusted Rand Index – ARI) használtam [10]. Az ARI a modell által jóslt klaszterek és a valós címkék közötti hasonlóságot méri azáltal, hogy párba állítja az adatpontokat, és megnézi, hogy a modell és a valóság ugyanoda sorolta-e őket. A mutató nagy előnye, hogy tartalmaz egy javító tényezőt, amely kiszűri a tisztán véletlenszerű egybeesések esélyét. Értéke leggyakrabban 0 és 1 között alakul, ahol az 1 a tökéletes egyezést, a 0 pedig a teljesen véletlenszerű csoportosítást jelenti.

Ugyancsak a külső kiértékelést szolgálja a Normalizált Kölcsönös Információ (Normalized Mutual Information – NMI) metrika [11]. Ez egy információelméleti alapú mutató, amely azt számszerűsíti, hogy mennyi közös információt oszt meg egymással a prediktált és a valós felosztás. Az NMI értéke szigorúan 0 és 1 közé esik, ahol az 1-es érték azt jelzi, hogy a klaszter-azonosítók ismeretében tökéletesen megmondható a valós orvosi diagnózis, a 0 pedig azt, hogy a két felosztás között nincs semmilyen összefüggés.

A szigorú matematikai és információelméleti metrikák (ARI, NMI) mellett a gyakorlati értelmezhetőség érdekében kiszámítottam a modellek klaszter-tisztaságát (Cluster Purity) is. Bár a felügyelet nélküli tanulásban a klasszikus osztályozási pontosság (accuracy) közvetlenül nem értelmezhető, a többségi szavazás (majority voting) elvével a klaszterek megfeleltethetők a valós címkéknek. Ennek során minden algoritmus által talált klaszterhez azt a valós orvosi diagnózist rendeltem hozzá, amely a klaszteren belül a legnagyobb arányban képviseltette magát. Az ezen a leképezésen lefuttatott pontosság-mérés egy rendkívül intuitív, klinikai szempontból is beszédes mutatót eredményezett: megmutatta, hogy ha a csoportokat a legjellemzőbb betegséggel azonosítanánk, az adatpontok hány százaléka kapna helyes besorolást.

1.5. Deep Learning alapú klaszterezés: DEC, IDEC bemutatása

A hagyományos felügyelet nélküli tanulási megközelítések általában két, egymástól független lépésből állnak: először egy jellemzőkinyerési (feature extraction) vagy dimenziócsökkentési lépést hajtanak végre, majd a kapott statikus reprezentáción lefuttatnak egy standard klaszterező algoritmust (például K-Means vagy GMM). A szakirodalom szerint ez a szétválasztott folyamat gyakran nem optimális eredményre vezet, mivel a jellemzőkinyerés során a modell nem kap visszacsatolást arról, hogy az előállított tér mennyire alkalmas a klaszterek elkülönítésére. Ennek a problémának a feloldására jött létre a mélytanulás alapú klaszterezés (*Deep Clustering*),

amely a jellemzők tanulását és a klaszterezési célfüggvény optimalizálását egyetlen, közös folyamatba integrálja.

Ezen a területen az egyik legjelentősebb áttörést Xie és munkatársai értékelték el a **DEC (Deep Embedded Clustering)** algoritmus bemutatásával [12]. A DEC egy olyan felügyelet nélküli módszer, amely mély neurális hálózatokat használ a magas dimenziójú adatok alacsonyabb dimenziós látens térbe (*latent space*) való leképezésére, miközben iteratíván optimalizálja a klaszter-hozzárendeléseket. A folyamat elméletileg két fő fázisra bontható:

1. **Előtanítás (Pre-training):** A modell egy mély autoenkóder (*Autoencoder*) segítségével inicializálja a paramétereit. A hálózat a bemeneti adatok sűrítését (Encoder) és visszanyerését (Decoder) végzi a rekonstrukciós hiba, tipikusan az átlagos négyzetes hiba (*Mean Squared Error, MSE*) minimalizálásával.
2. **Klaszterezési finomhangolás (Clustering Fine-tuning):** Az előtanítás után a dekódoló réteget eltávolítják. A kódoló kimenetén lévő látens térben a klaszterközéppontokat (centroidokat) inicializálják, majd a hálózat elkezd a reprezentációk átrendezését.

A DEC matematikai magját egy valószínűségi távolságmérés adja. Az algoritmus a Student-féle t-eloszlást használja arra, hogy kiszámítsa a látens térbe vetített adatpontok és a klaszterközéppontok közötti hasonlóságot (q_{ij} , lágy hozzárendelés vagy *soft assignment*). Ezt követően az algoritmus generál egy szigorúbb, mesterséges cél-eloszlást (p_{ij} , *target distribution*), amely felerősíti a magas valószínűségeket és elnyomja az alacsonyakat, ezáltal a klaszterek "tisztábbá" tételére ösztönöz. A hálózat súlyainak frissítése ezen két eloszlás közötti Kullback-Leibler (KL) divergencia minimalizálásával történik. Ez a veszteségfüggvény rákényszeríti a neurális hálózatot, hogy úgy torzítsa a beágyazási teret, hogy az adatpontok egyre közelebb kerüljenek a klaszterük középpontjához.

Bár a DEC jelentős javulást hozott a hagyományos módszerekhez képest, a szakirodalom rávilágított egy kritikus hiányosságára. Mivel a finomhangolás során a modell kizárólag a KL-divergenciát minimalizálja (és elhagyja a dekódolót), hajlamos arra, hogy túlságosan eltorzítsa a jellemzőteret (*feature space distortion*). A hálózat a klaszterek sűrítése érdekében olyan pontokat is egymás mellé vonzhat, amelyek az eredeti adattérben távol helyezkedtek el, így elvesztve az adatok eredeti topológiai és geometriai struktúráját.

Ezt a problémát orvosolja az **IDEC (Improved Deep Embedded Clustering)** architektúra, amelyet Guo és munkatársai publikáltak [13]. Az IDEC alapvető innovációja, hogy a klaszterezési finomhangolás során nem veti el a dekódoló (Decoder) ágat, hanem megtartja az autoenkóder teljes struktúráját.

Az IDEC modellek egy kombinált veszteségfüggvényt optimalizálnak:

$$L = L_{MSE} + \gamma L_{KL}$$

Ahol az L_{MSE} a rekonstrukciós hiba, az L_{KL} a klaszterezési hiba (KL-divergencia), a γ (gamma) pedig egy súlyozó hiperparaméter, amely a két cél közötti egyensúlyt szabályozza. Ez a kettős optimalizáció biztosítja, hogy a hálózat úgy növelje a klaszterek közötti szeparálhatóságot és a belső kohéziót, hogy közben folyamatosan garantálja a bemeneti adatok hiteles rekonstruálhatóságát. Az IDEC elméleti jelentősége abban rejlik, hogy a lokális adatszerkezet

(topológia) megőrzésével bizonyítottan robusztusabb és valóságosabb klaszterezési eredményeket képes elérni a komplex adathalmazokon.

2. Módszertan és saját munka

Ebben a fejezetben részletesen bemutatom a kísérleteim során alkalmazott módszereket, az adatok előkészítésétől kezdve egészen a különböző gépi tanulási modellek betanításáig és kiértékeléséig. A fejezet célja, hogy átláthatóan és lépésről lépésre dokumentálja az elvégzett gyakorlati munkát és a szoftveres megvalósítást.

A dolgozathoz elkészített teljes forráskód – az adatfeldolgozó szkriptekkel és a neurális hálózatok implementációjával együtt – elérhető egy nyilvános GitHub repozitóriumban [14]. Annak érdekében, hogy a leírt folyamatok könnyen visszakereshetők legyenek, az egyes alfejezetekben külön is utalok rá, hogy az ott bemutatott kód vagy Jupyter notebook pontosan melyik fájlban található meg a repozitóriumon belül.

2.1. Hardveres és szoftveres környezet

A tudományos kutatások, különösen a mélytanulás (deep learning) és az orvosi adatelemzés területén, szigorúan megkövetelik a reprodukálhatóságot. Annak érdekében, hogy a dolgozatban bemutatott gépi tanulási kísérletek validálhatók és a későbbiekben mások által is megismételhetők legyenek, elengedhetetlen a felhasznált hardveres és szoftveres infrastruktúra pontos dokumentálása.

2.1.1. Hardveres erőforrás

A kísérleteket és a teljes adatfeldolgozási folyamatot egy saját munkaállomáson, laptopon végeztem el. A CPU-igényes számítási feladatokat egy 11. generációs Intel Core i7-11800H processzoron végeztem, amelyet 32 GB rendszermemória (RAM) egészített ki. Ez a memóriakapacitás bőséges tartalékot biztosított a PTB-XL adathalmaz memóriában történő betöltéséhez és manipulációjához, mivel azt fokozatosan, és iteratíván tettem.

A kutatás legfontosabb részét képező mélytanulási alapmodellek (MOMENT) memóriába töltése, valamint a neurális hálózatok (DEC, IDEC) tanítása rendkívül számításigényes feladat (leginkább az embedder modell futtatása). Ennek hardveres gyorsítását egy dedikált NVIDIA GeForce RTX 3050 Laptop GPU végezte, amely viszont elég szűkös 2 GB videómemóriával (VRAM) rendelkezett, de elegendőnek bizonyult, és ezzel lehetővé tette a CUDA-alapú, lokális modellfuttatást.

2.1.2. Szoftveres platform és fejlesztői környezet

A fejlesztési környezet alapját Windows 11 operációs rendszer képezte. A projekt során felhasznált számos speciális programkönyvtár, szoftveres függőség (dependency) és azok verzióinak elkülönítése, valamint a lehetséges inkompatibilitási problémák elkerülése érdekében Conda virtuális környezetet alkalmaztam [16]. A szkriptek írása, a kísérletek iteratív tesztelése és a kiértékelés interaktív módon, Jupyter Lab környezetben [17] történt, Python 3.11.14-es programozási nyelvet használva.

2.1.3. Főbb felhasznált python könyvtárak

A kísérletek elvégzéséhez egy három fő fázisból álló adatcsővezeték-architektúrát (data pipeline) építettem fel, amely magában foglalja az **adatelőkészítést**, a **jellemzőkinyerést** (embedding) és a **klaszterezést** részeket. Az architektúra összes, részéhez a Python ökoszisztéma specifikus könyvtárait használtam fel.

Adatelőkészítés és feldolgozás

Az orvosi EKG-felvételek nyers, bináris formátumú (.dat és .hea) fájljainak beolvasásához a PhysioNet által biztosított **wfdb** (Waveform Database) könyvtárat alkalmaztam. A PTB-XL metaadatokat tartalmazó CSV fájlok betöltését és strukturált lekérdezését a **pandas** keretrendszer végezte. A stringben tárolt Python objektumok biztonságos átalakításához a beépített **AST** (Abstract Syntax Tree - Absztrakt Szintaxisfa) modul `literal_eval` függvényét használtam.

A beolvasott többdimenziós idősoros adatok (5000 adatpont, 12 elvezetés) matematikai reprezentációjáért és az esetleges hiányzó értékek kiegészítéséért a **numpy** könyvtár felelt. Annak érdekében, hogy a MOMENT beágyazó modell számára egységes méretű tenzorokat biztosítsak, a változó vagy túl nagy felbontású (500 Hz) EKG jelek hosszát egységesíteni kellett. Erre a feladatra a **scipy** könyvtár `interpolate` moduljának `interp1d` (egydimenziós lineáris interpoláció) osztályát alkalmaztam.

A könyvtárstruktúra bejárását, a fájlrendszer-műveleteket és a szkriptek argumentumainak kezelését az **os** és **sys** beépített modulok biztosították, míg a több tízezer fájl iteratív feldolgozásának vizuális nyomon követését a **tqdm** folyamatjelző könyvtárral valósítottam meg.

Jellemzőkinyerés (Embedding) és mélytanulás

A feldolgozott EKG jelek jellemzőkinyeréséhez a MOMENT alapmodellt (foundation model) alkalmaztam, amelynek betöltését és konfigurálását a specifikus **momentfm** Python könyvtár `MOMENTPipeline` osztálya biztosította. Mivel az alapmodellek architektúrája transzformer (transformer) alapú a számítások GPU-alapú gyorsításához és a tenzorműveletekhez a **PyTorch** keretrendszert használtam.

Ugyanez a keretrendszer adta az alapját a későbbiekben implementált Deep Embedding Clustering (DEC) és Improved DEC (IDEC) architektúráknak is. Ezek kódolásához a PyTorch beépített moduljait – mint a `torch.nn` a hálózati rétegek felépítéséhez, a `torch.optim` a súlyok frissítéséhez (pl. Adam és SGD), a `torch.nn.functional` a veszteségfüggvényekhez és aktivációs rétegekhez, valamint a `DataLoader` és a `TensorDataset` a betanítási batch-ek kezeléséhez – alkalmaztam. A számításigényes beágyazási és tanítási folyamatok során a szűkös VRAM kapacitás optimalizálása érdekében a memóriaszivárgások elkerülésére a Python beépített hulladékgyűjtőjét, a **gc** (garbage collector) modult használtam a szükségtelenné vált tenzorok manuális törlésére.

Klaszterezés, modelloptimalizálás és vizualizáció

A gépi tanulási kísérletek (Machine Learning) és az adatok statisztikai értékelése során a **scikit-learn** csomagot használtam legfőképp. Ebből a keretrendszerből importáltam a hagyományos

modelleket (például KMeans, GaussianMixture, LogisticRegression, RandomForestClassifier), a dimenziócsökkentési eljárásokat (PCA, TSNE), valamint az adat-standardizálást végző StandardScaler osztályt. A klaszterezési eredmények numerikus kiértékeléséhez szintén ennek a csomagnak a beépített metrikáit (például adjusted_rand_score, silhouette_score, accuracy_score) használtam.

A sűrűségalapú kísérletekhez a nemlineáris dimenziócsökkentést végző **umap-learn** könyvtárat, valamint a hierarchikus sűrűség-klaszterezéshez a **hdbscan** könyvtárat alkalmaztam. E modellek, továbbá a GMM hiperparamétereinek globális, Bayes-i optimalizálását az **optuna** keretrendszerrel valósítottam meg, amely a hagyományos, kimerítő "grid search" módszernél hatékonyabb paraméterter-feltérképezést tett lehetővé.

Végül, a kutatási eredmények, a klaszterek eloszlásának és a dimenziócsökkentett adatoknak a vizualizációjához a **plotly.express** modult választottam. Ennek segítségével interaktív, HTML alapú ábrákat generáltam.

2.2. Adatelőkészítés és tisztítás a PTB-XL-en

A gépi tanulási modellek, és különösen a nagyméretű mély neurális hálózatok (foundation models) hatékony betanításának és működésének elengedhetetlen feltétele a nyers adatok megfelelő strukturálása, tisztítása és standardizálása. A jelen kutatás adatcsővezeték-architektúrájának (data pipeline) első, és egyben egyik legkritikusabb fázisát a PTB-XL EKG-adathalmaz előfeldolgozása jelentette.

Ebben a fejezetben részletesen bemutatom a megvalósított adatfeldolgozási folyamatot. Elsőként ismertetem a nyers, orvosi metaadatok szűrését és az osztálycímkek tisztítását, majd bemutatom a többdimenziós idősoros EKG-jelek dimenzióinak egységesítésére alkalmazott interpolációs módszert, amelyet felhasználtam a későbbi jellemzőkinyerési (embedding) folyamatok sikeres végrehajtásához. Az ebben a fejezetben bemutatott adatelőkészítési folyamat teljes kódját a [a repozitórium /pipeline_scripts/data_concat/data_concat_with_interpolation.ipynb](#) fájljában találhatók.

2.2.1. A metaadatok feldolgozása és szűrése

A PTB-XL adathalmazban a diagnózisok úgynevezett SCP-ECG (Standard Communications Protocol for Computer Assisted Electrocardiography) kódok formájában vannak rögzítve, amely egy hivatalos nemzetközi szabvány. Ez azt jelenti, hogy ha egy orvos leírja azt, hogy valakinek szívinfarktus van, azt megfogalmazhatja szabad szöveggel rengeteg féle képpen ("infarktus", "AMI", "szívroham", "myocardiális infarktus", stb.), ami egy gépi tanulási modell feladatát jelentősen megnehezítené, vagy lehetetlenné tenné. Ezért minden féle képpen egy közös elnevezésre kellett volna hozni az azonos osztályba tartozó adatok címkéjét, viszont a szabvány alapú rögzítés ezt megoldotta helyettem. Ezen kívül, mivel a kardiológiában ritkán van 100%-os bizonyossággal megállapított betegség, így a formátum az adott betegségekhez egy valószínűségi értéket is rendelt. Például ebben a példában: {'NORM': 90.0, 'LHV': 15.0}, a kardiológus 90%-ig biztos, hogy ez egy normál EKG érték, de 15%-os esélyt talált valamilyen bal kamrai hipertrófiára (LHV). Mint ahogy a példában is látszik a formátum nem követeli meg, hogy a valószínűségi értékek összege 100% legyen, már csak azért is, mert több betegség is fennállhat egyszerre.

Első lépésben a *ptb_xl_database.csv* és a *scp_statements.csv* fájlok felhasználásával a nyers adatokat magasabb szintű, átfogó diagnosztikai főosztályokba (diagnostic superclass) egyesítettem. Ezt úgy tettem meg, hogy első lépésben a még kisosztály címkékből álló adatból eldobtam mindet, amely formai eltérésre, vagy ritmuszavarra utalt, azaz nem volt diagnózis kódjuk. Majd meghatároztam, hogy az adat melyik fő osztályba tartozik. Például ha volt olyan, amelynek az SCP kódja 'AMI' (Akut Myocardiális Infarktus) és 'IMI' (Alsófali infarktus) értékeket tartalmazott, akkor azt az 'MI' (Myocardiális Infarktus) főosztályba soroltam. Ha ebben ütközés volt, és a diagnózisok szerint két főosztályba is tartoztak, akkor kizártam a vizsgálatból.

A címkék szerepe a felügyelet nélküli tanulásban

Ezen a ponton fontos tisztázni az adathalmaz címkézettiségének kérdését. Bár a PTB-XL eredetileg egy felügyelt (címkézett) adathalmaz, a jelen dolgozat fókuszában felügyelet nélküli (unsupervised) algoritmusok állnak. Ez a gyakorlatban azt jelenti, hogy a klaszterező modellek (pl. K-Means, HDBSCAN) futtatása során ezeket a diagnosztikai címkéket *teljesen elrejtettem* az algoritmusok elől; a csoportosítás kizárólag az EKG jelekből kinyert matematikai jellemzők (embeddingek) alapján történt. A kiértékeléshez viszont muszáj felhasználnom a címkéket, amit többségi szavazás (majority voting) technikával rendelek az adatokhoz.

Mivel a dolgozat fő célja a felügyelet nélküli eljárások használata és a klaszterezés minőségének vizsgálata, a többértelműség elkerülése érdekében szigorú szűrést alkalmaztam. A felügyelet nélküli klaszterező algoritmusok (mint például a K-Means) hard-clustering módszert alkalmaznak, azaz egy adatpontot egyértelműen egyetlen klaszterbe sorolnak be, vagy zajként jelölnek meg (mint például a DBSCAN, vagy HDBSCAN). Ezért a több egymást átfedő betegséggel rendelkező páciensek rekordjait eltávolítottam az adathalmazból, és kizárólag azokat a méréseket tartottam meg, amelyek pontosan egy darab diagnosztikai főosztályhoz tartoznak. Ezzel a szűréssel az eredeti 21 837 rekordból álló halmazt 16 272 egycímkés (single-label) rekordra csökkentettem, ami egy sokkal tisztább adathalmazt biztosított a későbbi algoritmusok kiértékeléséhez, és ezzel biztosítottam, hogy a klaszterek jóságát mérő mutatókat – mint például a Korrigált Rand-index (ARI) vagy a Normalizált kölcsönös információ (NMI) – használni lehessen.

2.2.2 Az EKG jelek feldolgozása és dimenziói

A metaadatok szűrése után az eredeti, 500 Hz-es mintavételezéssel rögzített, nagyfelbontású fizikai adatsorokat dolgoztam fel. A **wfdb** könyvtárral történő bináris beolvasás után első lépésként ellenőriztem az adatok szerkezetét. A mérési rekordok a memóriában egy 2D-s *numpy.ndarray* típusú mátrixként jelentek meg, amelynek alakja (shape) (5000, 12). Ez a dimenzió pontosan lefedi a 10 másodperces rögzítési időtartam alatti 5000 diszkrét mintavételezési pontot, valamint a szív elektromos tevékenységét térben feltérképező 12 párhuzamos EKG elvezetést.

A valós klinikai mérések sajátosságából adódóan a jelek elvértve tartalmazhattak hiányzó vagy mérési hibából fakadó értékeket (NaN – Not a Number). Ezek kezelésére a hiányzó adatpontokat nullára (0.0) cseréltem. Ennek az egyszerű cserének az indoka az volt, hogy mivel az előfeldolgozott EKG jelek esetében a nulla érték jellemzően az izoelektromos vonalnak

(alapvonalnak) felel meg, ez a kitöltés nem hoz létre mesterséges, nagyfrekvenciás ugrásokat vagy zajokat a jelben. Ezzel a módszerrel biztosítottam a többdimenziós idősor folytonosságát, amely elengedhetetlen a mélytanulási modellek stabil bemenetéhez.

2.2.3. Interpoláció és egységesítés

A MOMENT-hez hasonló foundation modellek bemeneti tenzorai nem feltétlenül várnak fix dimenziót, de a beágyazások (embeddings) összehasonlíthatóságának, valamint a batch feldolgozásnak az érdekében az idősorokat egységes méretűre kellett hozni. Bár a PTB-XL adathalmaz tartalmazott 100 Hz-es minta-vételezésű (így alpból 1000 adatpont hosszúságú) változatot is, a dolgozatban az eredeti, 500 Hz-es adatokon végzett egydimenziós lineáris interpolációt (*scipy.interpolate.interp1d*) alkalmaztam. Ennek a döntésnek az volt az oka, hogy a kifejlesztett adatcsővezetéknek (pipeline) univerzálisnak kell lennie: képesnek kell maradnia bármilyen külső forrásból származó, eltérő mintavételezési gyakoriságú vagy hosszúságú EKG-jel fogadására és egységesítésére.

A lineáris interpoláció választását az indokolta, hogy a magasabb fokú (például spline) interpolációs algoritmusok hajlamosak mesterséges túllengéseket (Runge-jelenség) generálni a hirtelen frekvenciaváltozásoknál. Egy EKG-görbe esetében ez az anomália a diagnosztikai szempontból legfontosabb szakaszok, például a QRS-komplexusok torzulásához vezethetne. Az interpolációval elért egységes 1000-es célhosszúság (target length) garantálja, hogy a MOMENT modell attention-mechanizmusa minden esetben konzisztensen tudja értelmezni a bemenetet, függetlenül a felvétel eredeti paramétereitől.

Végül a feldolgozott adatokat 32 bites lebegőpontos (*np.float32*) formátumra konvertáltam, és bináris **numpy** (.*npy*) tömbökként mentettem el a háttértárra. Ez az optimalizációs lépés kettős előnnyel járt: egyrészt csökkentette a tárolási helyet a Python alapértelmezett 64 bites ábrázolásához képest, másrészt a .*npy* formátum minimalizálta az I/O (Input/Output) műveletek idejét, jelentősen felgyorsítva a későbbi jellemzőkinyerési fázis iteratív beolvasásait.

2.3. Jellemzőkinyerés a MOMENT modellel (embeddings generálása)

Az előfeldolgozott és egységesített EKG idősorok önmagukban még túlzottan magas dimenziójúak és zajosak lennének a klasszikus felügyelet nélküli tanulóalgoritmusok számára. Ezért a következő lépésben a kifejezetten idősoros adatokon előtanított AutoML/MOMENT-1-large alapmodellt (foundation model) alkalmaztam egy alacsonyabb dimenziójú beágyazás (embedding) létrehozására. A jellemzőkinyerési folyamatot a **momentfm** és a **PyTorch** könyvtárak segítségével, GPU (CUDA) gyorsítással valósítottam meg a számítási idő csökkentése érdekében.

Ebben a fejezetben részletesen bemutatom a foundation modell inicializálásának mérnöki lépéseit, beleértve a feladatspecifikus beállításokat is. Ezt követően kitérek a figyelem-mechanizmushoz (attention) szorosan kapcsolódó bemeneti maszkolás (input mask) logikájára, végezetül pedig ismertetem azokat a szigorú memóriakezelési stratégiákat, amelyek elengedhetetlenek voltak a nagyméretű (large) architektúra szűkös memóriakapacitású lokális hardveren történő stabil futtatásához. Ezen fejezetben bemutatott jellemzőkinyerés teljes kódja

a repozitórium `/pipeline_scripts/data_embedding/data_embedding_new.ipynb` fájljában található.

2.3.1. A MOMENT alapmodell elméleti háttere és működése

A kutatás során alkalmazott *MOMENT: A Family of Open Time-series Foundation Models* egy kifejezetten idősoros adatok elemzésére kifejlesztett nyílt forráskódú alapmodell (foundation model), amelyet a Carnegie Mellon Egyetem AutonLab kutatócsoportja publikált [2]. A gépi tanulás területén az alapmodellek olyan robusztus, nagyméretű architektúrákat jelentenek, amelyek hatalmas mennyiségű, diverz adaton történő általános előtanítást követően finomhangolás nélkül is képesek specifikus feladatok (például anomália detektálás, osztályozás vagy jellemző kinyerés) elvégzésére.

A MOMENT architektúrájának magját a modern mesterséges intelligencia kutatásban, különösen a nagy nyelvi modelleknél (LLM) áttörést hozó Transformer hálózat adja. A Transformer architektúra önfigyelmi mechanizmusának (self-attention) köszönhetően a modell kiválóan alkalmas az idősoros adatokon – mint amilyenek a jelen dolgozatban vizsgált sokdimenziós EKG-jelek is – belüli komplex, lokális és hosszú távú összefüggések egyidejű megragadására. A kísérletekhez az architektúra „large”, azaz nagyméretű változatát (MOMENT-1-large) használtam. Ez a változat több százmillió optimalizálható paraméterének (pontosabban 314 millió) köszönhetően kiemelkedő reprezentációs képességgel rendelkezik, így hatékonyan képes kinyerni a rejtett mintázatokat a nagyfelbontású fiziológiai jelekből [2]. A most bemutatott felhasználáson kívül a MOMENT modell képes még előrejelzés (forecast), osztályozás (classification), anomália észlelés (anomaly detection), és adatpótlás (imputation) feladatok megoldására.

A MOMENT modell rendkívüli generalizációs képessége az úgynevezett „Time-series Pile” nevű, hatalmas és rendkívül változatos idősoros adathalmazon történő előtanításnak (pre-training) köszönhető [2]. Ennek a kiterjedt és erőforrásigényes előtanításnak az a legfőbb előnye, hogy a hálózat súlyai már optimalizáltak az idősorok dinamikájának, frekvenciaváltozásainak és alapvető topológiai mintázatainak felismerésére. Jelen kutatás szempontjából kiemelten fontos döntés volt, hogy a feldolgozás során a modellt nem tanítottam tovább (nem végeztem rajta finomhangolást vagy domain-specifikus súlyfrissítést). Ehelyett tudatosan a gyári állapotú alapmodell robusztus, általánosított jellemzőkinyerési (feature extraction) képességeire támaszkodtam a komplex EKG-jelek feldolgozásakor.

Bár a MOMENT architektúrája több különböző idősoros feladatra (például előrejelzésre, anomália detektálásra vagy hiányzó adatok imputációjára [15]) is képes, a kísérletek során feladat-specifikusan kizárólag a beágyazási (embedding) funkcióját hívtam meg. Ebben az operációs módban a modell a korábban előkészített és interpolált, 1000 adatpont hosszúságú EKG-jeleket egy sűrített, 1024 dimenziós folytonos matematikai vektorra – más néven rejtett állapottá (hidden state) – alakítja át. Ez a nemlineáris transzformáció elengedhetetlenül fontos a pipeline-ban: a nyers, zajos és nehezen interpretálható fiziológiai jeleket egy olyan tömör beágyazási térbe (embedding space) vetíti, amelyen a későbbi felügyelet nélküli klaszterező algoritmusok az euklideszi vagy koszinusz-távolságok alapján képesek operálni.

2.3.2. A bemeneti adatok standardizálása és tenzorralakítása

A feldolgozási folyamat (pipeline) első lépéseként a nyers, .npy formátumú EKG adatokat töltöttem be. Mivel a valós orvosi adatok (különösen a szenzoros mérések) esetenként hiányosak vagy hibásak lehetnek, a betöltést követően egy adatminőség-ellenőrzési lépést hajtottam végre: az esetlegesen előforduló hiányzó értékeket (NaN - Not a Number) numerikus nullával helyettesítettem (*np.nan_to_num*) a számítási hibák elkerülése miatt.

Az adattisztítást a jellemzők skálázása követi. Ehhez a **scikit-learn** könyvtár *StandardScaler* algoritmusát alkalmaztam. A standardizálás elengedhetetlen lépés a mélytanulási modellek stabilitása és megfelelő konvergenciája érdekében, mivel az egyes EKG csatornák (elvezetések) eltérő amplitúdókkal és statisztikai jellemzőkkel rendelkezhetnek. Az eljárás minden egyes jellemzőt nulla várható értékűre és egységnyi szórására, azaz normális eloszlására transzformál.

Mivel a MOMENT modell **PyTorch** keretrendszerre épül, a standardizált **NumPy** tömböket **PyTorch** tenzorokká (*torch.tensor*) konvertáltam, még hozzá 32 bites lebegőpontos pontossággal (*torch.float32*). A nyers adatok eredetileg kétdimenziós mátrixként, (Idő, Csatornák) felbontásban érkeztek – például a PTB-XL adatbázis esetén jellemzően 1000 időpillanattal és 12 csatornával (1000, 12). A MOMENT modell bemeneti rétege azonban egy háromdimenziós, (Batch, Csatornák, Idő) formátumú tenzort vár el. Ennek a szigorú bemeneti követelménynek a teljesítéséhez az adatmátrixot először transzponáltam majd egy új kiterjedést, egy úgynevezett *batch* dimenziót adtam hozzá a **PyTorch** *unsqueeze(0)* függvényével. Ennek eredményeként az adatok felveszik a szükséges (1, 12, 1000) alakzatot.

A feldolgozás utolsó előkészítő lépéseként egy bemeneti maszkot (*input_mask*) generáltam a memóriában csupa egyes értékekből (*torch.ones*), amely pontosan illeszkedik az adattenzor dimenzióihoz. Ez a maszk jelzi a Transformer architektúra önfigyelmi (self-attention) mechanizmusa számára, hogy a tenzor minden eleme valós és releváns adat, amelyet figyelembe kell venni a beágyazások (embeddingek) kiszámítása során. Abban az esetben ha valahol nulla értéket adtam volna meg, az azt jelentette volna a modellnek, hogy az az érték nem releváns, és nem kell figyelembe venni a jellemzőkinyerés folyamatban.

2.3.3. A modell inicializálása és az input maszkolás

A beágyazások (embeddings) előállításához a **momentfm** könyvtár *MOMENTPipeline* osztályát hívtam segítségül. A modell inicializálása során a paraméterezést úgy állítottam be, hogy az kifejezetten a jellemzőkinyerés feladatra fókuszáljon. Erre a célra az *AutonLab/MOMENT-1-large* elnevezésű, előtanított súlyokat tartalmazó változatot töltöttem be. Mivel a neurális hálózat futtatása jelentős számítási kapacitást igényel, a kódban implementáltam egy hardveres ellenőrzést, amely lehetővé tette, hogy amennyiben rendelkezésre áll NVIDIA GPU, a modellt a CUDA architektúrára mozgassam (*model.to(device)*). Ezzel a megoldással többszörösére gyorsítottam a feldolgozást a CPU-alapú végrehajtáshoz képest.

A kísérlet során kritikus szempont volt, hogy a modell ne tanuljon tovább, hanem fix jellemzőkinyerőként működjön, ezért a hálózatot kiértékelő (*eval*) módba kapcsoltam. A tényleges jellemzőkinyerési ciklusban az összes számítást a *torch.no_grad()* kontextuskezelő blokkon belül végeztem el. Ezzel explicit módon letiltottam a gradiensszámítást és a

visszaterjesztést (backpropagation), ami drasztikusan csökkentette a GPU memórafoglalását, és lehetővé tette a nagy mennyiségű EKG rekordok hatékony, szekvenciális feldolgozását.

2.3.4. Az inferencia folyamata és a memóriakezelés

Az inferencia szakaszban a célom a teljes, több mint 16 ezer EKG rekordból álló adathalmazon való hatékony jellemzőkinyerési folyamat futtatása volt. Mivel egy nagyméretű (large) alapmodell alkalmazása rendkívüli erőforrásigénnyel jár, a folyamatot egy iterációs ciklusba szerveztem. A futtatás során a **tqdm** könyvtár segítségével valós idejű haladási naplót vezettem, amely lehetővé tette a feldolgozási sebesség és a hátralévő idő pontos nyomon követését.

A hatékonyság növelése érdekében a szkriptben implementáltam egy ellenőrző mechanizmust, amely a feldolgozás előtt megvizsgálta, hogy az adott EKG fájlhoz tartozó beágyazás már elkészült-e a célkönyvtárban. Ez a megközelítés lehetővé tette a folyamat megszakítását és későbbi folytatását anélkül, hogy a korábban már legenerált, számításigényes eredményeket újra elő kellett volna állítanom.

A modell kimenetén egy 1024 dimenziószámú reprezentációt kaptam alapértelmezetten (1, 1024) formátumban. A pipeline belső logikában egy elágazást készítettem, amelyben lekezeltem a neurális hálózat kimeneti tenzorának az elvárttól különböző variációit, ezzel biztosítva a robusztus működést:

- **Alapeset:** Amennyiben a kapott reprezentáció a várt kétdimenziós formátumban érkezett (*Batch, Jellemző*), a nulladik dimenziót – amely a batch méretét jelöli – a `.squeeze()` függvénnyel eltávolítottam. Mivel a feldolgozás során egyszerre mindig csak egy mintát adtam be a modellnek, ez a dimenzió redundánssá vált, így az átalakítás után egy tiszta, 1024 elemű vektort kaptam.
- **Háromdimenziós kimenet esete:** Ha a kimenet valamilyen okból háromdimenziós formátumban érkezett volna, az adatokon az első dimenzió mentén kiátlagolást végeztem volna. Ezzel a lépéssel a tenzort az alapesetben elvárt (1, 1024) méretűre módosítottam, majd ezen is elvégeztem a `.squeeze()` műveletet a végleges forma eléréséhez.
- **Egyéb eset:** Amennyiben a kimenet a fentiekől eltérő alakot vett volna fel, a `.flatten()` függvénnyel egyetlen folytonos adatsorrá lapítottam volna a tenzort, felkészülve az (1024, 1) vagy hasonló elrendezésekre.

Minden elágazás végén a kapott kimenetet átalakítottam **NumPy** tömbbé a későbbi könnyebb kezelhetőség érdekében. A futtatás során folyamatosan ellenőriztem a kimeneti adatok formáját, és hiba esetén hibaüzenetet írtam ki a konzolra. A gyakorlati futtatás során minden bemeneti elem az alapesetnek megfelelő kimenetet produkálta, így a jellemzőkinyerés fennakadás nélkül zajlott le.

A MOMENT-1-large modell használata során a szűk keresztmetszetet a videomemória (VRAM) véges kapacitása jelentette. Annak érdekében, hogy elkerüljem a kritikus memóriatúlszordulási hibákat (*Out of Memory error*), többszintű memóriakezelési stratégiát alkalmaztam:

- Minden egyes fájl feldolgozása után a feleslegessé vált átmeneti tenzorokat és változókat az explicit del paranccsal töröltem a memóriából.
- Manuálisan meghívtam a Python beépített szemétgyűjtőjét (`gc.collect()`), kényszerítve a rendszer erőforrásainak felszabadítását.
- A **PyTorch** keretrendszer `torch.cuda.empty_cache()` függvényével rendszeresen ürítettem a GPU gyorsítótárát, megakadályozva a memória fragmentációját.

Az inferencia eredményén elvégzett trnszformációk következtében minden egyes méréshez egy 1024 dimenziójú kimeneti vektort kaptam. Ezeket a sűrű, absztrakt reprezentációkat az `np.save()` függvény segítségével .npy kiterjesztésű fájlkként mentettem el a háttértárra. Ez a megoldás lehetővé tette, hogy a későbbi klasszifikációs és klaszterezési feladatokhoz már közvetlenül ezeket a jellemzővektorokat használjam fel, biztosítva az adatok integritását és a gyors hozzáférést a további elemzésekhez.

2.4. Felügyelet nélküli osztályozási kísérletek és adatrepresentáció validálása

Az 1024 dimenziós beágyazások (embeddingek) legenerálását követően a kutatásomban a következő szakaszhoz érkeztem: meg kellett vizsgálnom, hogy a MOMENT alapmodell által létrehozott absztrakt tér mennyire hordozza magában az orvosi diagnózisok szerinti releváns információkat, és ezek az információk kinyerhetők-e felügyelet nélküli tanulási módszerekkel.

A kísérleti folyamatot egy szisztematikus, több lépcsőből álló folyamat szerint építettem fel. Első lépésként egy alapvonal (baseline) kísérletet végeztem a klasszikus K-Means algoritmus segítségével, hogy referenciapontot kapjak a klaszterezési metrikák (Sziluett-pontszám, ARI, NMI) tekintetében. Mivel azonban a felügyelet nélküli tanulás sikere nagyban függ az adatok belső struktúrájától, elengedhetetlennek tartottam a beágyazások minőségének validálását is. Ezt a validációt felügyelt tanulási algoritmusokkal (Logisztikus Regresszió és Random Forest) végeztem el. Úgy tekintettem ezekre a modellekre, mint a beágyazó tér „információtartalmának mérőeszközeire”: ha egy felügyelt modell képes nagy pontossággal elkülöníteni a diagnosztikai osztályokat, az bizonyítja, hogy a klaszterezési nehézségek nem a jellemzőkinyerési folyamat sikertelenségéből, hanem az algoritmusok paraméterezéséből, az adatok nem megfelelő, nem tiszta klaszterekbe való elkülönéséből, vagy a dimenziók átkából fakadhatnak.

A kezdeti eredmények alapján a kísérleteket kiterjesztettem modernebb, sűrűségalapú megközelítésekre (DBSCAN, HDBSCAN), valamint vizsgáltam a dimenziócsökkentés (PCA, UMAP) és a normalizáció hatását a szétválasztható csoportok kialakulására. Külön figyelmet fordítottam az adathalmaz egyenetlen eloszlására, ezért a teljes adathalmazon végzett mérések mellett kiegyensúlyozott (balanced) almintákon is lefuttattam a használt algoritmusokat, és modelleket. Végezetül a merev klaszterhatárok feloldása érdekében valószínűségi modellezéssel (GMM) és mély beágyazott klaszterezéssel (DEC) próbáltam optimalizálni az eredményeket, keresve azt a konfigurációt, amely a leginkább fedi a klinikai valóságot. A felügyelt és felügyelet nélküli klaszterezési kísérletek teljes kódja a repozitórium `/pipeline_scripts/data_classification/` mappájában található. Az egyes módszerek részletes bemutatásakor pontosan hivatkozom majd a vonatkozó fájlokra.

2.4.1. Alapvonal (Baseline) kísérlet: K-Means klaszterezés

A kutatásom során a viszonyítási alap (baseline) megteremtésére a K-Means algoritmust választottam. Ez egy euklideszi távolságalapú, iteratív partícionáló eljárás, amelynek célja az adathalmaz felosztása olyan csoportokra, ahol a pontok és a hozzájuk tartozó klaszterközéppontok (centroidok) közötti négyzetes távolság összege minimális.

Mivel a K-Means rendkívül érzékeny a bemeneti változók skálázására – az eltérő nagyságrendű jellemzők torzíthatják a távolságszámítást –, az 16 272 darab, egyenként 1024 dimenziós beágyazást a klaszterezés előtt a **Scikit-learn** könyvtár *StandardScaler* osztályával standardizáltam. Ezzel biztosítottam, hogy minden dimenzió nulla várható értékkel és egységnyi szórással járuljon hozzá a modell döntéseihez.

A modell inicializálásakor a klaszterek számát (k) 5-ben határoztam meg, igazodva a PTB-XL adathalmazban definiált öt orvosi főosztályhoz (NORM, MI, STTC, CD, HYP). A robusztusabb eredmények elérése és a lokális minimumokba való beragadás elkerülése érdekében az $n_init=10$ paramétert használtam, így az algoritmust tíz különböző véletlenszerű inicializálással futtattam le, majd a belső metrikák alapján a legjobb eredményt választottam ki. A kísérlet reprodukálhatóságát fix véletlenszám-generátor maggal ($random_state=42$) rögzítettem.

A klaszterezés kiértékelési metrikái

Bár a klaszterezés alapvetően felügyelet nélküli folyamat, a kísérlet ezen fázisában a valódi diagnosztikai címkék rendelkezésre álltak, így a modell teljesítményének mérésére belső és külső metrikák kombinációját határoztam meg:

- **Silhouette Score:** Ezzel a belső metrikával a klaszterek kohézióját (a pontok közelsége a saját középpontjukhoz) és szeparáltságát (a pontok távolsága a szomszédos klaszterektől) mértem.
- **Adjusted Rand Index (ARI):** Külső metrikaként a prediktált klaszterek és a valódi orvosi osztályok közötti egyezés vizsgálatára alkalmaztam, amely korrigálja a véletlenszerű csoportosításból adódó torzításokat.
- **Normalized Mutual Information (NMI):** Ennek segítségével azt elemeztem, hogy a predikciók és az eredeti eloszlás között mennyi a normalizált közös információtartalom.

Az így kapott eredmények és a baseline kísérlet kiértékelése a 4. fejezetben kerülnek bemutatásra. (/pipeline_scripts/data_classification/data_clustering.ipynb)

2.4.2. A MOMENT beágyazások validálása felügyelt tanulással

A K-Means algoritmus kezdeti gyenge teljesítménye (amelyet a 4. fejezetben részletezek) kritikus döntési pont elé állított a kutatásom során. Felmerült bennem a kérdés, hogy a MOMENT modell által generált 1024 dimenziós beágyazások egyáltalán tartalmazznak-e elegendő klinikai információt a betegségek elkülönítéséhez. Tisztában voltam vele, hogy amennyiben a beágyazások nem reprezentálják megfelelően az EKG jelek sajátosságait, a kutatásom további része – a felügyelet nélküli klaszterezés finomhangolása – értelmetlenné

válik, amennyiben nem tudtam volna megoldani, hogy a MOMENT valóban tanulható reprezentációkat tudjon előállítani. Emiatt egy felügyelt tanulási (*supervised learning*) validációs kísérletet hajtottam végre, amely próbája volt a MOMENT által kapott jellemzővektorok minőségének.

A kísérlet során a modellek számára elérhetővé tettem a valódi (*ground truth*) diagnosztikai címkéket, hogy megvizsgáljam azt, hogy elméletileg lehetséges-e az osztályok szétválasztása ebben a 1024 dimenziós térben. A folyamatot az adatok előkészítésével kezdtem. A beágyazott vektorokat és a hozzájuk tartozó címkéket összefésültem, majd a `train_test_split` függvény segítségével 80-20% arányban tanító- és tesztalmazra bontottam az adatsort. Az összehasonlíthatóság érdekében a bemeneti jellemzőket itt is standardizáltam.

Két eltérő logikájú algoritmust választottam a validációhoz:

1. **Logisztikus Regresszió (LR):** Ezzel a lineáris modellel azt teszteltem, hogy az osztályok egy egyszerű hipersíkkal elválaszthatóak-e a térben, azaz a beágyazó modell lineárisan szeparálható módon rendezte-e el az információkat.
2. **Random Forest (RF):** Ezzel a nemlineáris, döntési fákon alapuló modellel a komplexebb, hierarchikus összefüggések meglétét vizsgáltam.

A modellek tanítása során kiemelt figyelmet fordítottam a kiértékelési stratégia megválasztására. Mivel az adathalmazom erősen kiegyensúlyozatlan volt – ahol a NORM osztály dominanciája mellett bizonyos betegségtípusok (mint a HYP) csak csekély esetszámban fordultak elő –, a globális pontosság (*Accuracy*) mellett a makro átlagolt F1-pontszámot (*Macro F1-score*) és az osztályonkénti visszahívást (*Recall*) határoztam meg fő metrikákként, amelyeket könnyen a **Scikit-learn** könyvtár `classification_report` függvényével ki tudtam számolni. Úgy véltem, ezek a mutatók fogják valódi pontossággal megmutatni, hogy a MOMENT modell képes-e a ritka diagnosztikai mintázatokat is sűrített formában megőrizni.

Ez a validációs lépés szolgált alapul a további munkámhoz. Úgy tekintettem rá, mint egy biztosítékra: ha a felügyelt modellek képesek sikeresen tanulni ezekből a vektorokból, akkor igazoltnak látom a beágyazások minőségét, és folytathatom a kísérleteket a sűrűségalapú és valószínűségi klaszterező modellek irányába.
(/pipeline_scripts/data_classification/data_classification.ipynb)

2.4.3. Sűrűségalapú megközelítés

A K-Means algoritmus távolságalapú megközelítésének metodikai korlátai miatt a kutatásomat a sűrűségalapú (*density-based*) klaszterező eljárások irányába folytattam. Ezek az algoritmusok – ellentétben a K-Means-szel – elméletben nem feltételeznek rögzített, gömbszimmetrikus klaszterformát, képesek az adatok közötti folytonos átmenetek kezelésére, valamint a kiugró értékek (anomáliák) zajként (*noise*) történő azonosítására.

Első kísérletként a hagyományos DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) algoritmust alkalmaztam közvetlenül az 1024 dimenziós beágyazási téren. A kísérleti beállítások során az algoritmus legfontosabb hiperparaméterét, az `eps` (a klaszterezéshez vizsgált környezet sugara) távolságot egy rácskeresés (*grid search*) keretében 5,0 és 50,0 közötti tartományban variáltam. Céлом az volt, hogy azonosítsam a magas

dimenziójú térben azt a sűrűségi küszöböt, amely mentén az orvosi diagnózisok elválnak egymástól.

Mivel a magas dimenziószám (a „dimenziók átka”) miatt a sűrűségalapú távolságmérés veszít a hatékonyságából, a folyamatba integráltam egy dimenziócsökkentési lépést. A kezdeti, lineáris PCA transzformációkat követően egy fejlettebb, nemlineáris eljárást, az UMAP-ot (*Uniform Manifold Approximation and Projection*) alkalmaztam. Ennek az algoritmusnak a kiválasztását az indokolta, hogy a transzformáció során a globális struktúrák mellett képes megőrizni az adatok lokális topológiai viszonyait is. Az UMAP segítségével a 1024 dimenziós beágyazásokat egy nagyságrendekkel kisebb, 10–15 dimenziós térbe sűrítettem.

A dimenziócsökkentett adatokon a fejlettebb HDBSCAN (*Hierarchical DBSCAN*) algoritmust alkalmaztam, amely hierarchikus megközelítésének köszönhetően kevésbé érzékeny a globális sűrűségi paraméterekre, mint a sima DBSCAN. Az optimális konfiguráció megtalálása érdekében egy kiterjesztett, 576 kombinációból álló hiperparaméter-keresést hajtottam végre. A keresés során egyidejűleg optimalizáltam az UMAP dimenziócsökkentő paramétereit (például a szomszédok számát és a minimális távolságot), valamint a HDBSCAN klaszterezési paramétereit (`min_cluster_size`, `min_samples`).

A kísérletvezetés során kritikus szempont volt a modell „őszinteségének” biztosítása. A sűrűségalapú modellek ugyanis hajlamosak a metrikák mesterséges javítására azáltal, hogy a nehezen besorolható vagy határvonalas adatpontokat egyszerűen zajnak minősítik, vagy indokolatlanul sok apró, jelentéktelen klasztert hoznak létre (túlszegmentálás). Ennek megakadályozására a kiértékelési folyamatba két szigorú korlátozást (*constraint*) építettem be a hiperparaméter-optimalizálás során:

- **MAX_NOISE_RATIO (0.30):** Megköveteltem, hogy a modell az adatok legalább 70%-át érvényes klaszterbe sorolja be, így a maximálisan megengedett zajarányt 30%-ban korlátoztam.
- **MIN_CLUSTERS és MAX_CLUSTERS (3–10):** A túlszegmentálás elkerülése érdekében a klaszterek számát az orvosilag is indokolt 5 főosztály nagyságrendjének környezetére szorítottam.

(/pipeline_scripts/data_classification/data_clustering_dbscan.ipynb,
(/pipeline_scripts/data_classification/data_clustering_umap_hdbscan.ipynb))

2.4.4. Kiegyensúlyozott adathalmaz és optimalizálási keretrendszer

A klaszterezési feladatok sikerességét alapvetően határozza meg a bemeneti adatok minősége, az adateloszlás jellemzői, valamint a felhasznált modellek hiperparamétereinek precíz hangolása. Ebben a fejezetben azt a programozott keretrendszert mutatom be, amely biztosítja az adatok torzításmentes előkészítését és a globális optimalizációs folyamatok automatizálását.

Alapbeállítások és a konfigurációs blokk kialakítása

Egy komplex, több modellt és iteratív kísérleteket (study-kat) bemutató adatelemzési projekt esetében a reprodukálhatóság és a kód karbantarthatósága kritikus szempont. Ennek

szellemében a kódstruktúra legelején egy egységes, központosított konfigurációs blokk került kialakításra.

Ez a megközelítés több szinten is előnyös. Elsőként, a környezeti és futtatási változók (mint például az elérési utak, vagy az algoritmusok determinisztikus működését garantáló `RANDOM_STATE`) kiemelése megelőzi a kódba bevészt (hard code-olt) számok használatát. Sokkal fontosabb azonban, hogy az Optuna optimalizáló keretrendszer számára szükséges keresési terek (search spaces) és az őszinteségi kikötések (constraints) is itt lettek globális szótárakként (dictionary) definiálva.

Ilyen például a `HDBSCAN_SPACE` vagy a `GMM_SPACE`, amelyek pontosan rögzítik a vizsgálandó paraméterek (pl. szomszédok száma, minimum klaszterméret) alsó és felső határait. Szintén ide kerültek a peremfeltételek, mint a maximálisan megengedett zajarány vagy a klaszterszámok korlátai. Ezt a megközelítés lehetővé teszi, hogy a későbbiekben az optimalizálási határokat egyetlen helyen lehessen módosítani, anélkül, hogy a mélyebben fekvő, optimalizációt végző függvények belső logikájába bele kellene nyúlni.

A kiegyensúlyozott adathalmaz inspirációja és implementációja

Az eredeti adathalmaz feltáró adatelemzése során egyértelművé vált egy a modellezést esetlegesen befolyásolható probléma: a célváltozók (betegség típusok) közötti drasztikus egyensúlyhiány (class imbalance). Amíg a 'NORM' (normál) esetek több mint kilencezer (9083) mintával dominálták az eseteket, addig a ritkább kategóriák – mint például a 'HYP' osztály – mindössze 536 megfigyeléssel rendelkeztek.

Bár a felügyelet nélküli tanulás (unsupervised learning) során az algoritmusok nem használják fel a címkéket a tanuláshoz, az adatok eloszlásának sűrűsége drámai hatással van az eredményre. A sűrűség alapú klaszterező algoritmusok, mint amilyen a HDBSCAN is, az erősen alulreprezentált osztályokat hajlamosak pusztán izolált, alacsony denzitású zajként (noise) értelmezni és eldobni, vagy ami még rosszabb: egyszerűen beolvasztani őket a masszívan domináns osztályok kiterjedt klasztereibe. Annak érdekében, hogy a modellek a ritkább betegség típusok rejtett mintázatait (manifold) is eséllyel észrevegyék, a kiegyensúlyozatlan adathalmazon történő futtatások mellett elengedhetetlenné vált egy mesterségesen kiegyensúlyozott adathalmaz (Balanced Dataset) megalkotása.

A kiegyensúlyozás implementációja során az "undersampling" (alul-mintavételezés) stratégiáját választottam. Ennek során minden egyes osztályból véletlenszerűen, de a `RANDOM_STATE` által reprodukálható módon, pontosan a legkisebb elemszámú osztály méretének megfelelő (536 darab) mintát vettem ki. Ezeket a részhalmazokat egyesítve egy tökéletesen kiegyensúlyozott, összesen 2680 megfigyelést tartalmazó, torzításmentes adathalmazt kaptam.

A mintavételezést követően az adatok megfelelő matematikai reprezentációjának kialakítása következett. Mivel a dimenziócsökkentéshez használt UMAP jellemzően koszinusz-távolságot (cosine distance), a HDBSCAN pedig euklideszi távolságot (euclidean distance) használ, a bemeneti tér skálázása elengedhetetlen volt. A jellemzőket először egy `StandardScaler` segítségével z-score normalizációnak vettem alá, hogy minden változó azonos nagyságrendbe (nulla várható érték, egységnyi szórás) kerüljön, kiküszöbölve az eltérő mértékegységekből

fakadó dominanciát. Ezt követően az adatmátrix sorain L2 normalizációt (normalize) hajtottam végre, amely az adatpontokat egy egységsugarú hipergömbre (hypersphere) vetíti. Ezzel a dupla transzformációs lépéssel próbáltam a koszinusz-távolság alapú dimenziócsökkentés stabilitása és a klaszterek szeparálhatósága által a szeparálhatóságot növelni

Hiperparaméter-optimalizálás az Optuna keretrendszerrel

A gépi tanulási modellek, különösen a komplex, dimenziócsökkentéssel kombinált klaszterező csővezetékek (pipeline-ok) esetében a hiperparaméterek manuális hangolása szinte lehetetlen feladat. Ennek automatizálására az Optuna keretrendszert integráltam, amely a hagyományos Grid Search (rácskeresés) kimerítő és lassú módszerével szemben intelligens, Bayes-i optimalizáción alapuló keresést hajt végre.

A kód implementációja során a magasabb rendű függvények (higher-order functions) és a *closure* (lezárás) koncepcióját alkalmaztam. Ahelyett, hogy egyetlen globális objective függvényt hoztam volna létre, külső függvényeket (wrapper functions) írtam a modellekhez: a `create_hdbscan_study` és a `create_gmm_study`. Ezek a függvények bemenetként kapják meg az éppen aktuális adatot (`X_data`), a valós címkéket (`true_labels`), valamint a konfigurációs blokkban rögzített keresési tereket (`space`) és peremfeltételeket (`constraints`). Az Optuna által megkövetelt objective függvény *ezen a burkolófüggvényen belül* van definiálva. Ennek a megközelítésnek a legnagyobb előnye a modularitás: a belső objective függvény "emlékszik" a külső paraméterekre, így a keretrendszer mindenféle kódDuplikáció vagy globális változók használata nélkül képes ugyanazt az optimalizálási logikát futtatni hol a teljes, hol pedig a generált kiegyensúlyozott adathalmazon.

2.4.5. HDBSCAN + UMAP és GMM + PCA implementációja a keretrendszerben

A HDBSCAN + UMAP csővezeték optimalizációja: A `create_hdbscan_study` belső logikája egyszerre végzi a dimenziócsökkentés és a klaszterezés paramétereinek hangolását, hiszen ezek egymásra hatással vannak. Az objective függvényben az Optuna `trial.suggest_*` módszisaival dinamikusan mintavételeztem az UMAP szomszédsági (`n_neighbors`) és sűrűségi (`min_dist`) paramétereit, majd a HDBSCAN klaszterméret (`min_cluster_size`) és sűrűségi (`min_samples`) értékeit.

A modellépítés során az UMAP koszinusz-távolság alapján egy alacsonyabb dimenziós térbe ágyazza a bemeneti adatokat (`X_umap`), majd a HDBSCAN euklideszi távolságméréssel megkeresi benne a sűrűsödési pontokat. Ezt követi a rendszer megkötései, az ösztintességi kikötések érvényesítése. Mivel a HDBSCAN képes adatpontokat zajként (-1 osztályba sorolni) azonosítani, fennáll a veszélye, hogy az optimalizáló egy olyan könnyű megoldást talál, ahol a pontok 90%-át zajnak bélyegzi, a maradék 10%-on pedig tökéletes metrikát ér el. Ennek megakadályozására a kód kiszámítja a talált klaszterek számát (`n_clusters`) és a zajarányt (`noise_ratio`). Ha a modell átlépi a konfigurációban megadott zaj-limitet (pl. túl sok a zaj), vagy nem találja meg a minimálisan elvárt klaszterszámot (esetleg túl sokat talál), a függvény azonnal egy -1.0-ás (büntető) értékkel tér vissza. Ezzel az Optuna próbálkozását abba az irányba kényszerítve, hogy csak a valós, értelmezhető tartományban keressen. Ha a modell átmegy ezen

a szűrőn, a teljesítményét az *Adjusted Rand Score (ARI)* segítségével mértem, kizárólag a magpontokon (ahol labels != -1), azaz a zajt figyelmen kívül hagyva.

A GMM + PCA csővezeték optimalizációja

A `create_gmm_study` hasonló felépítési elvekre épül, de az algoritmus sajátosságaihoz igazodik. Itt a dimenziócsökkentést a determinisztikusabb PCA (Principal Component Analysis) végzi, amelynek komponens-számát (`n_components_pca`) az Optuna hangolja. A Gaussian Mixture Model (GMM) esetében nemcsak numerikus értékeket, hanem kategorikus hiperparamétereket is optimalizálunk: a kovariancia-mátrix típusát (`covariance_type`, pl. 'full', 'diag', 'tied') és az inicializációs stratégiát (`init_params`, pl. 'kmeans', 'random').

Mivel a GMM egy valószínűségi modell és "puha" klaszterezést (soft clustering) végez, minden adatpontot besorol valamelyik eloszlásba – azaz nem hoz létre explicit zajt, mint a HDBSCAN. Emiatt az ösztönzési kikötések (mint a zajarány vizsgálata) itt okafogyottá válnak. A GMM célfüggvénye így jóval letisztultabb: a csővezeték lefutása után a prediktált címkéket közvetlenül összeveti a valós címkékkel, és a teljes adathalmazon számított *Adjusted Rand Score*-t adja vissza maximalizálandó (`direction="maximize"`) célfüggvény-értékként

A végső modellek kiértékelési stratégiája

Az optimalizációs folyamat (`study-k`) lefutása és a legjobb hiperparaméterek kiválasztása után – amire segítséggel volt az optuna legjobb paraméterek automatikus elmentési rendszere – szükségem volt egy olyan egységes, standardizált függvényre, amellyel a különböző algoritmusok (HDBSCAN, GMM) teljesítményét objektíven, ugyanazon metrikák mentén tudtam összehasonlítani. Ennek érdekében implementáltam az `evaluate_final_model` nevű egyedi kiértékelő függvényt, amely bemenetként a valós osztálycímkéket (`true_labels`), a modell által generált predikciókat (`pred_labels`), valamint a modell nevét kapta meg.

A kiértékelés első lépéseként a klaszterezés alapvető strukturális jellemzőit vontam ki. Meghatároztam a modell által talált klaszterek számát (`n_clusters`), amelynél külön odafigyeltem arra, hogy a HDBSCAN által zajnak minősített, -1-es azonosítójú pontokat ne számoljam önálló klaszternek. Ezzel párhuzamosan kiszámítottam a zajarányt (`noise_ratio`), ami a sűrűségalapú modellek értékelésénél egy fontos indikátor a modell használhatóságát illetően.

A függvény legfontosabb részét a matematikai teljesítménymetrikák kiszámítása adta. Úgy döntöttem, hogy a metrikákat kizárólag a valid, címkéken értékelem ki, ehhez egy maszkot (`valid_idx = pred_labels != -1`) hoztam létre. Erre azért volt szükség, hogy az esetlegesen magas zajarány ne torzítsa el lefelé a ténylegesen megtalált klaszterek minőségi mutatóit. Ezeken a magpontokon két metrikát számítottam ki: az Adjusted Rand Indexet (ARI) és a Normalized Mutual Informationt (NMI). Mindkét metrika kiválóan alkalmas a prediktált klaszter-struktúra és a valós címkék közötti hasonlóság mérésére, függetlenül attól, hogy a klaszterek abszolút azonosítói eltérnek a valós osztálynevektől.

A függvény legösszetettebb lépése, az úgynevezett Klaszter Tisztaság (Cluster Purity Accuracy) kiszámítása volt. Mivel a felügyelet nélküli tanulás során a modellek nem a valós címkék (pl.

betegségnevek) alapján prediktálnak, a hagyományos pontosság (accuracy) közvetlenül nem értelmezhető.

Elsőként inicializáltam egy üres, a predikciókkal megegyező méretű tömböt (mapped_preds), a valós címkéket pedig a könnyebb adatkezelés érdekében egy pandas Series objektummá alakítottam. Ezt követően iteráltam a prediktált, érvényes klaszter-azonosítókön. Minden egyes klaszternél meghatároztam az oda tartozó adatpontok indexeit (idx), majd megkerestem, hogy ezeken az indexeken a valós címkék közül melyik fordul elő a legnagyobb arányban. Ezt a domináns, többségi osztályt (majority disease) tekintettem a klaszter "valódi" identitásának, és a mapped_preds tömbben a klaszter minden egyes pontjához ezt a többségi címkét rendeltem hozzá.

Végül ezen a leképezett, felcímkézett tömbön és a valós osztályokon lefuttattam a standard accuracy_score függvényt (szigorúan csak a valid pontokra szűrve). Ez a metrika végeredményben azt az értéket mutatta meg számomra, hogy ha minden egyes talált klasztert a benne lévő leggyakoribb betegséggel azonosítanék, akkor a zajmentes adatpontok hány százalékát diagnosztizálnám helyesen. A robusztus működés érdekében a függvényt elláttam egy hibakezelő (edge-case) ággal is, amely figyelmeztetést dob, ha a modell egyetlen valid klasztert sem talál, és mindent zajként azonosít. (/pipeline_scripts/data_classification/data_clustering_umap_hdbscan_balanced.ipynb)

2.5. Mélytanulás alapú klaszterezés (Deep Clustering)

A hagyományos és sűrűségalapú gépi tanulási kísérletek rávilágítottak arra, hogy az osztályok közötti geometriai átfedések miatt a beágyazási tér további, célzott finomhangolására (fine-tuning) van szükség. Ennek megvalósítására a mélytanulás alapú klaszterezés (Deep Clustering) felé fordultam, megvizsgálva a DEC (Deep Embedding Clustering) és az IDEC (Improved Deep Embedding Clustering) architektúrákat. Az ebben a fejezetben leírtak a repozitórium /pipeline_scripts/data_classification/data_clustering_dec.ipynb fájljában található.

2.5.1. Adatelőkészítés és az Autoencoder felépítése

A korábbi tapasztalatokra építve a tanítási folyamathoz a többségi osztályok torzító hatásának elkerülése érdekében a feladatmegoldásnak ebben a részében csak a teljesen kiegyensúlyozott (balanced) adatsort használtam. A NORM, MI, STTC, CD és HYP osztályok mindegyikéből pontosan 536 mintát választottam ki véletlenszerűen, így egy 2680 elemből álló, standardizált (StandardScaler) bemeneti tenzort hoztam létre.

A DEC és IDEC modellek alapját egy mély alulkomplett autoencoder (Undercomplete Autoencoder) képezi, amelynek feladata a 1024 dimenziós MOMENT beágyazások további tömörítése egy 10 dimenziós látens térbe, ezzel a tömörítési ráta 102,4-szeres. Az Encoder (kódoló) rétegei a következőképpen épültek fel: 1024 -> 500 -> 100 -> 10 neuron. A nemlineáris reprezentációk tanulása érdekében ReLU aktivációs függvényeket, az eltolódások elkerülésére pedig BatchNorm1d rétegeket alkalmaztam.

A hálózat kódolójának (Encoder) 10 dimenziós kimenetét egy L_2 normalizáción ($F.normalize(p=2)$) futtattam keresztül. Ezt a transzformációt azért alkalmaztam, mert az alapmodellek (mint a MOMENT) jellemzően az irányban hordozzák a szemantikai információt.

Az L_2 normalizáció biztosítja a kimeneti vektorok egységnyi hosszát, vagyis a látens teret mesterségesen egy hipergömb felületére korlátozza. Ezzel a vetítéssel a hagyományos euklideszi távolságmérés – amit például a K-means is használ – matematikailag egyenértékűvé válik a koszinusz-hasonlósággal (cosine similarity). Így kiküszöbölhető a vektorok magnitúdójából eredő torzítás, és garantálható, hogy az ezt követő klaszterezési folyamatok a beágyazások összehasonlításának standard módszerén alapuljanak. Ebből a normalizált, 10 dimenziós látens térből kiindulva a dekódoló (Decoder) hálózat szimmetrikusan épült fel az eredeti dimenziók visszaállítására: 10 -> 100 -> 500 -> 1024 neuronos rétegekkel.

2.5.2. A DEC és IDEC modellek implementációja és architektúrája

Miután az autoenkóder előtanításával képes lett a hálózat az EKG adatok sűrített reprezentációjának előállítására, a kódoló (Encoder) és dekódoló (Decoder) egységeket alapul véve építettem fel a komplex klaszterező modelleket. A megvalósításhoz egyedi **PyTorch** modulokat definiáltam, amelyek lehetővé tették a látens tér dinamikus átrendezését.

A DEC (Deep Embedding Clustering) implementációja: A DEC modell megalkotásakor a korábban előtanított autoenkóder kódoló részét használtam fel. A szoftveres megvalósítás során a kódoló kimenetére egy egyedi klaszterező réteget (*ClusteringLayer*) illesztettem, amely a klaszterközpontokat (centroidokat) tanítható paraméterekként (`nn.Parameter`) tárolta. A réteg feladata az volt, hogy kiszámítsa a látens térbe vetített EKG minták és a centroidok közötti hasonlóságot. Ehhez a Student-féle t-eloszláson alapuló kernelt implementáltam, amely a pontok és középpontok közötti euklideszi távolságot egy valószínűségi értékre (úgynevezett *soft assignment*) konvertálta. A DEC modell futtatása során a dekódoló ágot explicit módon elhagytam, így a hálózat kizárólag a klaszterezési célfüggvény optimalizálására fókuszált.

Az IDEC (Improved DEC) implementációja: Ebben a struktúrában a kódoló és a klaszterező réteg mellett megtartottam a dekódoló (Decoder) ágot is. A modell *forward* függvényében a hálózat egyidejűleg állította elő a látens térbeli hasonlósági eloszlást és a bemeneti 1024 dimenziós jellemzővektor rekonstrukcióját.

A tanítási ciklusban a komplexitást a veszteségfüggvények kombinálása jelentette. Egy összetett célfüggvényt határoztam meg, amely a klaszterezési hibát (KL-divergencia) és a rekonstrukciós hibát (MSE) együttesen kezelte (képlet: $L = L_{MSE} + \gamma L_{KL}$, részletesebben az 1.5. fejezetben). A két komponens súlyozására egy globális „gamma” paramétert vezettem be, melynek értékét a notebookban végzett kísérletek alapján 0,8-ban rögzítettem. Ezzel a megoldással biztosítottam, hogy az optimalizáló algoritmus (Adam) 80%-os súllyal a klaszterek sűrítésére, 20%-os súllyal pedig az EKG adatok eredeti topológiai tulajdonságainak megőrzésére törekedjen. Ez az architektúra garantálta, hogy a modell a látens tér átrendezése közben ne veszítse el a diagnosztikailag releváns információkat.

2.5.3. A hálózatok hiperparaméterei és a tanítási folyamat

A hálózatok betanítása három, egymásra épülő fázisban történt a **PyTorch** keretrendszerben. A folyamat során figyelmet fordítottam a megfelelő veszteségfüggvények (loss functions) kiválasztására és az optimalizálási stratégiákra.

1. Fázis: Az Autoencoder előtanítása (Pre-training)

Mielőtt a modell képes lenne értelmes klasztereket képezni, meg kell tanulnia a bemeneti 1024 dimenziós EKG-adatok alapvető jellemzőit (feature extraction). Az előtanítás célja a kódoló (Encoder) és dekódoló (Decoder) súlyainak inicializálása. A hálózat előtanítását 200 epoch hosszan végeztem. A tanulás során az átlagos négyzetes hibát (Mean Squared Error) alkalmaztam veszteségfüggvényként, amely a hálózat bemenete és a dekódoló által rekonstruált kimenet közötti különbséget bünteti. A súlyok frissítését Adam optimalizálóval végeztem (tanulási ráta: 0,001), 256-os kötegméretet (batch size) alkalmazva. Az előtanítás végére az MSE veszteség stabilizálódott, ami jelezte, hogy az autoencoder sikeresen megtanulta az adatok sűrített reprezentációját.

2. Fázis: Klaszterközéppontok inicializálása

A finomhangolás megkezdése előtt a kódoló által generált 10 dimenziós téren lefuttattam egy K-Means algoritmust. Ez a lépés elengedhetetlen a DEC algoritmus DECLayer rétegének inicializálásához, mivel a hálózat innen kezdi el finomhangolni a centroidokat. A kezdeti középpontokat többségi szavazás (majority voting) módszerrel rendeltem hozzá a megfelelő osztályhoz. Majd a K-Means algoritmus eredményét ki is értékeltem egy baseline érték megadása érdekében.

3. Fázis: Finomhangolás (Fine-tuning)

A hálózatok végső tanítása eltérően zajlott a DEC és az IDEC architektúrák esetében:

- **A DEC modell finomhangolása:** A DEC esetében a dekódoló réteget elhagytam. A finomhangolás 150 epochon keresztül zajlott, ADAM optimalizálóval (tanulási ráta: 0,01, momentum: 0,9). A veszteségfüggvény a Kullback-Leibler (KL) divergencia volt, amely a szoftt-hozzárendelések (q) és egy mesterségesen "tisztított" cél-eloszlás (target distribution, p) közötti eltérést minimalizálja. A stabilitás érdekében a cél-eloszlást nem minden lépésben, hanem csak 5 iterációnként (update_interval) frissítettem.
- **Az IDEC modell finomhangolása:** Az IDEC architektúra megtartotta a dekódolót, így a modellnek 150 epochon keresztül egyidejűleg kellett minimalizálnia a klaszterezési hibát (KL Loss - L_{KL}) és a rekonstrukciós hibát (MSE Loss - L_{MSE}). A két veszteség kombinációját a γ paraméter szabályozta, amelyet 0,8-ban határoztam meg. Ennek optimalizálásához az Adam algoritmust (tanulási ráta: 0,0005) használtam.

3. Eredmények és kiértékelés

Ebben a fejezetben a korábban részletezett módszertani kísérletek kvantitatív és kvalitatív eredményeit mutatom be, valamint értékelem ki azokat az orvosi diagnosztika és a gépi tanulás kontextusában. A kiértékelés elsődleges célja, hogy választ adjon a kutatásom alapvető kérdéseire: megfelelő minőségű reprezentációt biztosít-e a MOMENT alapmodell az EKG-jelek elemzéséhez, és milyen hatékonysággal lehet ezeket a magas dimenziós beágyazásokat felügyelet nélküli eljárásokkal a valós diagnózisoknak megfelelő klaszterekbe rendezni.

Az áttekinthetőség és a logikai felépítés érdekében az eredményeket a kísérletek elvégzésének sorrendjében, négy fő alfejezetre bontva ismertetem:

1. **A beágyazások validálása felügyelt tanulással:** Először a Logisztikus Regresszió és a Random Forest osztályozók teljesítményét mutatom be. Ezekkel az eredményekkel bizonyítom, hogy a 1024 dimenziós beágyazások felügyelt tanulással szeparálható, releváns klinikai információkat tartalmaznak-e.
2. **Az alapvonal (baseline) kísérlet korlátai:** A második részben a K-Means algoritmus metrikáit (Sziluett-pontszám, ARI, NMI, és Accuracy Score) és kétdimenziós vizualizációit elemzem, kiértékelve a geometriai és távolságalapú klaszterezés eredményeit, és hogy kudarcot vallot-e.
3. **Fejlett klaszterezési eljárások optimalizálása kiegyensúlyozott adathalmazon:** A harmadik alfejezetben a sűrűségalapú (HDBSCAN) és a valószínűségi (Gaussian Mixture Model – GMM) megközelítések eredményeit tárgyalom. Mivel mindkét algoritmus hiperparaméter-optimalizálását az Optuna keretrendszerrel, a kisebbségi osztályok torzításának kiküszöbölése érdekében kiegyensúlyozott (*balanced*) adatsoron végeztem el, itt mutatom be számszerűen, hogyan kezelték ezek a modellek a szembe érkező problémákat.
4. **Mély beágyazott klaszterezés (DEC/IDEC) eredményei:** Végül a statikus tereket elhagyva kiértékelem, hogy az autoenkóderekre épülő, dinamikus tér-átrendezést alkalmazó neurális hálózatok (DEC és IDEC) tudták-e javítani a adatok felépítésében lelt hibákat.

Az eredmények bemutatása során a numerikus teljesítménymutatók mellett nagy hangsúlyt fektetek a vizuális reprezentációra (tévesztési mátrixok, dimenziócsökkentett eloszlásábrák), hogy a tanítás során felállt nehézségeket, és a levont következtetéseket alátámasszam.

3.1. A hagyományos modellek eredményei

Ebben a fejezetben értékelem ki az alkalmazott felügyelt tanulási módszerek eredményeit, amelyeket a MOMENT beágyazások validálására használtam. Majd a további felügyelet nélküli próbálkozásaimból adódó eredményeket mutatom be, hasonlítom össze és értékelem ki.

3.1.1. A MOMENT beágyazások validálása felügyelt tanulással

A felügyelet nélküli klaszterezési kísérletek kezdeti nehézségei (alacsony Sziluett-pontszám és ARI értékek) miatt – amelyet a következő fejezetben fogok kiértékelni – fontosnak tartottam annak ellenőrzését, hogy a MOMENT alapmodell által generált 1024 dimenziós reprezentációk egyáltalán hordoznak-e elegendő diagnosztikai információt. Ehhez a kísérlethez a felügyelt tanulás módszertanát hívtam segítségül, ahol a modellek a tanítás során hozzáfértek a PTB-XL adathalmaz valódí diagnosztikai címkéihez.

A kísérlet során két eltérő logikájú modellt, a Logisztikus Regressziót (LR) és a Random Forestet (RF) tanítottam be a beágyazásokon. Az adathalmazt 80-20% arányban osztottam fel, így a teszhalmazban 3255 minta szerepelt.


A Random Forest eredményei és a pontosság csapdája

A Random Forest osztályozó futtatása után első látásra rendkívül meggyőző, **74,44%-os globális pontosságot (Accuracy)** kaptam. Ez az érték lényegesen magasabb volt minden

korábbi kísérletemnél, azonban a részletes osztályozási jelentés (Classification Report) elemzése rávilágított egy súlyos problémára.

Detailed Classification Report – Random Forest				
	Precision	Recall	F1-score	Support
CD	0.91	0.51	0.66	342
HYP	0.00	0.00	0.00	107
MI	0.71	0.40	0.51	508
NORM	0.72	0.96	0.82	1817
STTC	0.70	0.52	0.60	481
Accuracy	---	---	0.73	3255
Macro avg	0.61	0.48	0.52	3255
Weighted avg	0.71	0.73	0.70	3255

A táblázatból és a modell tévesztési mátrixából is világosan látszott, hogy a Random Forest „csalt” a tanítás során: a magas pontszámot az adathalmaz kiegyensúlyozatlanságának kihasználásával érte el. Szinte minden mintát a többségi (NORM) osztályba sorolt, ahol 0,96-os visszahívási arányt (Recall) produkált, miközben a kisebbségi osztályokat teljesen figyelmen kívül hagyta. A legsúlyosabb hiba a HYP (hipertrófia) osztálynál jelentkezett, ahol a visszahívási arány **0,00** volt, vagyis a modell egyetlen ilyen beteget sem ismert fel. Emiatt a makro F1-pontszáma mindössze 0,52 lett.



A Logisztikus Regresszió és a lineáris szeparálhatóság bizonyítása

A valódi áttörést a Logisztikus Regresszió hozta meg. Bár a globális pontossága alacsonyabb volt (66,64%), a makro F1-pontszáma (0,57) és az osztályonkénti eloszlása sokkal kiegyensúlyozottabb teljesítményt mutatott. Ez a modell nem csak a többségi osztályra fókuszált: a CD (vezetési zavar) osztályt 75%-os, a ritka HYP osztályt pedig 34%-os sikerrel ismerte fel.

Detailed Classification Report – Logistic Regression				
	Precision	Recall	F1-score	Support
CD	0.56	0.75	0.64	342
HYP	0.12	0.34	0.17	107
MI	0.62	0.65	0.63	508
NORM	0.87	0.67	0.76	1817
STTC	0.59	0.70	0.64	481
Accuracy	---	---	0.67	3255
Macro avg	0.55	0.62	0.57	3255
Weighted avg	0.73	0.67	0.69	3255

Konklúzió

A felügyelt validáció eredményei kulcsfontosságúnak gondolom a szakdolgozat szempontjából. A Logisztikus Regresszió sikere bebizonyította, hogy a MOMENT modell által létrehozott 1024 dimenziós tér **lineárisan szeparálható**. Ez azt jelenti, hogy az EKG jelekből kinyert jellemzővektorok igenis tartalmazzák a diagnózishoz szükséges információkat, csak azok a magas dimenziószám miatt olyan komplex elrendeződést mutatnak, amelyet egy egyszerű, euklideszi távolságra épülő, és 1024 dimenzióban operáló felügyelet nélküli algoritmus (mint a K-Means) nem képes hatékonyan kezelni. Ez az eredmény adott alapot és motivációt a kutatásom folytatásához a sűrűségalapú és mélytanulási klaszterezési eljárások irányába.

3.1.2. A távolságalapú klaszterezés korlátai (K-Means alapvonal)

Miután a felügyelt osztályozási kísérletekkel bebizonyítottam, hogy a MOMENT-beágyazások hordoznak diagnosztikailag releváns információkat, a kutatásomat a felügyelet nélküli tanulás irányába folytattam. Viszonyítási alapként (baseline) a K-Means algoritmust alkalmaztam az adathalmaz mind a 16 272 mintáján. Céлом az volt, hogy megvizsgáljam, vajon a legegyszerűbb, euklideszi távolságon és geometriai középpontokon alapuló modell képes-e szétválasztani a 1024 dimenziós teret az orvosi diagnózisoknak megfelelően.

A klaszterezési metrikák és a tisztaság mutató

A modell lefutását követően az általános klaszterezési metrikák rendkívül gyenge teljesítményt mutattak. A belső kohéziót vizsgáló Silhouette-pontszám mindössze 0,0824 lett, ami arra utal, hogy az adatok a térben nem képeznek élesen elkülönülő "szigeteket", hanem határok nélkül, sűrűn egymásba lógva helyezkednek el. Ezt a feltevést a külső metrikák is megerősítették: a korrigált Rand-index (ARI) 0,0570, míg a normalizált közös információ (NMI) 0,0746 lett. Ezek az értékek matematikailag azt mutatják, hogy az algoritmus által meghúzott geometriai határok szinte semmilyen összefüggést nem mutatnak a valós betegségsoportokkal.


Érdekes anomáliaként jelentkezett ugyanakkor a klaszterek tisztasági mutatója (Purity Accuracy), amely első ránézésre egy elfogadható, 59,03%-os eredményt adott. Ennek a látszólagos ellentmondásnak a feloldására egy részletes osztályozási jelentést (Classification Report) készítettem. A klaszterekhez többségi szavazással (*majority voting*) rendeltem hozzá az osztálycímkeket, majd összevettem azokat a valódi diagnózisokkal.

Detailed Classification Report – K-Means (baseline)				
	Precision	Recall	F1-score	Support
CD	0.69	0.32	0.43	1709
HYP	0.00	0.00	0.00	536
MI	0.00	0.00	0.00	2538
NORM	0.59	1.00	0.74	9083
STTC	0.00	0.00	0.00	2406
Accuracy	---	---	0.59	16272
Macro avg	0.26	0.26	0.23	16272
Weighted avg	0.40	0.59	0.46	16272

A táblázat egyértelműen megmutatja a tisztasági mutató által is kifejezett osztály-kegyensúlyozatlanságot. A modell a 0,59-es pontosságot kizárólag a legnagyobb elemszámú, NORM osztály (9083 minta) sikeres besorolásával érte el. A részletes metrikák megmutatták, hogy a makro átlagolt F1-pontszám mindössze 0,23 volt, ami egyértelmű kudarcnak tekinthető. A K-Means az öt klaszterből egyetlen egyet sem jelölt meg úgy, amelyben a HYP, MI vagy STTC betegek lettek volna többségben ezeknél a visszahívási arány, a Recall 0,00 volt.

Vizuális megerősítés és a kudarc szakmai okai

A numerikus eredményeket a kísérlet során generált tévesztési mátrix vizuálisan is



alátámasztotta.

Ahogy az ábrán is jól látható, az algoritmus az adatok döntő többségét egyetlen hatalmas, a NORM osztály klaszterébe ömlesztette. Példának okáért a 2538 MI betegből 2368-at, míg a ritka HYP (hipertrófia) osztályba tartozó betegekből 527-et, a teljes állomány szinte 100%-át a normál EKG-k közé sorolt be.

Ebből a kísérletből azt a következtetést vontam le, hogy a 1024 dimenziós EKG-beágyazások elemzésekor a hagyományos távolságalapú klaszterezés eléri a módszertani határait. Ennek két fő oka van. Egyrészt a "dimenziók átka" miatt a magas dimenziószámú térben a pontok közötti euklideszi távolságok elmosódnak, és a mutató erejük jelentősen csökken. Másrészt az osztályok közötti egyenlőtlen eloszlás (a NORM dominanciája) miatt a K-Means által

feltételezett azonos méretű, gömbszimmetrikus klaszterek fizikailag nem illeszkednek a valódi EKG adatok elrendeződéséhez.

Ezek az eredmények tették indokolttá, hogy a kutatásomat a távolságalapú modellektől a sűrűségalapú és a valószínűségi osztályozási megközelítések (HDBSCAN, GMM), majd később a mélytanulósos tér-átrendezés (DEC) irányába folytassam.

3.1.3. Fejlett klaszterezési eljárások optimalizálása

A geometriai alapú K-Means algoritmus korlátainak felismerése után a kutatásomat a sűrűségalapú (HDBSCAN) és a valószínűségi (Gaussian Mixture Model – GMM) klaszterező eljárások irányába folytattam. Annak érdekében, hogy a modellekből a maximális teljesítményt hozzam ki, a hiperparaméter-keresést az Optuna optimalizációs keretrendszerrel végeztem el. A kiértékelést első lépésben a teljes, 16 272 mintát tartalmazó eredeti adathalmazon hajtottam végre, fenntartva az eredeti, erősen aszimmetrikus osztályeloszlást.

A sűrűségalapú megközelítés: UMAP és HDBSCAN

A sűrűségalapú klaszterezés során a magas dimenziószám kezelésére egy UMAP dimenziócsökkentő lépést integráltam a folyamatba, mint azt a 2. fejezetben is említettem. Az Optuna keretrendszer által azonosított legjobb konfiguráció a következő volt: az UMAP esetében 38 szomszédot (`n_neighbors: 38`) és 0,15-ös minimális távolságot (`min_dist: 0.151`) találta a legjobbnak, míg a HDBSCAN algoritmusnál a minimális klaszterméretet 31-ben (`min_cluster_size: 31`), a minimális mintaszámot pedig 21-ben (`min_samples: 21`) határozta meg a kereső.

Ezzel a beállítással a modell összesen 7 klasztert talált. Az eredmények rámutattak a sűrűségalapú eljárások egyik jellegzetes tulajdonságára az átfedő adathalmazokon: a modell az adatok közel egyharmadát, 28,9%-át zajként (Noise Ratio) azonosította, ami éppen csak alatta maradt a korábban definiált 30%-os küszöbértékemnek. Az érvényes pontokon mért korrigált Rand-index (ARI) 0,1199-re, az NMI pedig 0,1323-ra emelkedett. Bár a klaszterek tisztasági mutatója (Purity Accuracy) 60,9% lett, ez az érték továbbra is magában hordozta az osztály-kiegyensúlyozatlanság torzító hatását, mivel alig haladta meg a legnagyobb (NORM) osztály globális arányát.

A valószínűségi megközelítés: GMM

A HDBSCAN szigorú, zajt is szűrő mechanizmusával szemben a GMM egy lágy (*soft*) klaszterezési logikát követ, amely minden egyes adatponthoz valószínűségeket rendel, így a zajarány definíció szerint 0,0%. A modell futtatása előtt a teret PCA segítségével optimalizáltam; a legjobb eredményt 17 főkomponens (`n_components_pca: 17`) megtartásával, a kovarianciamátrix pedig teljesre (`covariance_type: 'full'`) állításával találta az optimalizáló.

A GMM modell kiválóan teljesített a teljes adathalmazon: pontosan 5 klasztert különített el, amely megegyezik a PTB-XL adathalmaz orvosi főosztályainak számával. Az ARI mutató jelentős ugrást produkált a korábbi kísérletekhez képest, elérve a **0,2391**-es értéket, míg az NMI 0,1525 lett. A klaszterek tisztasága itt is 61,1%-on álltandósult.

Konklúzió az eredeti adathalmazon

Az eredmények bizonyították, hogy az elliptikus eloszlásokat feltételező valószínűségi modellezés (GMM) alkalmasabb az EKG-beágyazások struktúrájának leírására, mint a merev távolságokon alapuló vagy a zajokat elvető sűrűségalapú eljárások. Azonban mindkét modellnél megfigyelhető volt, hogy a tisztasági mutató (Purity) 61% körül tetőzött. Ez a statisztikai plafon arra engedett következtetni, hogy a modellek döntéseit még mindig dominálta a NORM osztály hatalmas túlsúlya. Annak érdekében, hogy a modellek valós, kisebbségi betegségekre (pl. HYP, MI) vonatkozó szeparáló képességét objektíven meg tudjam ítélni, elengedhetetlenné vált a kísérletek megismétlése egy teljesen kiegyensúlyozott (*balanced*) adathalmazon.


A modellek teljesítményének vizsgálata kiegyensúlyozott adathalmazon

A teljes adathalmazon tapasztalt, 61% körüli tisztasági (Purity) plafon egyértelművé tette, hogy a modellek teljesítményét torzítja az osztály-kiegyensúlyozatlanság. Annak érdekében, hogy megvizsgáljam a sűrűségalapú és valószínűségi algoritmusok valós, szeparáló képességét – azaz, hogy mennyire képesek az egymással egyenrangú betegségcsoportok között különbséget tenni –, a kísérleteket egy kiegyensúlyozott (*balanced*) adatsoron is megismételtem. Ebben a halmazban minden diagnosztikai osztályból azonos számú (536 darab) mintát hagytam meg, így a teljes elemszám 2680-ra csökkent. Az Optuna keretrendszerrel a hiperparaméter-keresést ezen az új, szigorúbb adatteren is elvégeztem.

A kiegyensúlyozott adathalmazon a **HDBSCAN** modell optimalizálása során az UMAP szomszédsági paramétere 11-re (`n_neighbors: 11`), a minimális távolság 0,29-re (`min_dist: 0.291`), míg a HDBSCAN minimális klasztermérete 47-re (`min_cluster_size: 47`) módosult. Az eredmények drasztikus visszaesést mutattak a teljes adathalmazhoz képest: a modell mindössze 3 érvényes klasztert tudott azonosítani, miközben az adatok 29,3%-át továbbra is zajnak (besorolhatatlannak) bélyegezte. A korrigált Rand-index (ARI) **0,0280**-ra zuhant, a klaszterek tisztasági mutatója (Purity Accuracy) pedig a realisabb, **30,7%-os** szintre állt be az érvényes pontokon.

Ezzel szemben a **GMM (Gaussian Mixture Model)** a kiegyensúlyozott adatokon is stabilabb maradt, bár a teljesítménye itt is mérséklődött. A 36 főkomponensre (`n_components_pca: 36`) illesztett, teljes kovarianciamátrixú valószínűségi modell sikeresen megtalálta az elvárt 5 klasztert. A zajarány (módszertani okokból) 0,0% maradt, az ARI mutató **0,0835** lett, míg a klaszterek tisztasága elérte a **38,1%-ot**.

Detailed Classification Report – GMM (balanced)				
	Precision	Recall	F1-score	Support
CD	0.42	0.52	0.47	536
HYP	0.00	0.00	0.00	536
MI	0.00	0.00	0.00	536
NORM	0.36	0.57	0.44	536
STTC	0.34	0.73	0.46	536
Accuracy	---	---	0.36	2680
Macro avg	0.22	0.36	0.27	2680
Weighted avg	0.22	0.36	0.27	2680



Szakmai értékelés és átvezetés a mélytanulás felé

A kiegyensúlyozott adathalmazon kapott eredmények kulcsfontosságú felismeréshez vezettek. Amikor megszüntettem a többségi osztály dominanciájából fakadó statisztikai "illúziót", a metrikák (30-38%-os tisztaság) megmutatták a MOMENT-beágyazások geometriai, és a tanulási algoritmusok módszertani határait. A HDBSCAN kudarca és a GMM szerényebb pontossága matematikailag is igazolta azt a geometriai tényt, hogy a különböző EKG-eltérőzések az 1024 dimenziós térben hatalmas átfedésben léteznek.

Ezek a statikus megközelítések (akár távolság-, akár sűrűség-, akár valószínűség-alapúak) elérték a határaikat: elfogadták a teret olyanak, amilyenek az alapmodell generálta azt. A klaszterek közötti élesebb elválasztás és a tisztaság további növelése érdekében egyértelművé vált, hogy fel kell hagyni a statikus jellemzőtér elemzésével. A kutatás következő, legösszetettebb fázisában ezért a tér dinamikus, mélytanulás-alapú átrendezésére (Deep Embedded Clustering) tértem át, ahol a neurális hálózat már kifejezetten a betegcsoportok szeparálhatóságának maximalizálására optimalizálta a beágyazásokat.

3.2. DEC és IDEC modellek eredményei

A kutatásom utolsó fázisában a hagyományos gépi tanulási modellek által felállított korlátokat a mélytanulás alapú, dinamikus tér-átrendezést alkalmazó architektúrákkal kíséreltem meg áttörni. A vizsgálatot a kiegyensúlyozott (*balanced*) adathalmazon hajtottam végre, 10 dimenziós látens térben. A kiindulási alap (baseline) meghatározásához a 10 dimenziós reprezentációkon először egy hagyományos K-Means klaszterezést futtattam le, amely 37,5%-os tisztaságot (Purity) és 0,0679-es ARI értéket eredményezett. Ezt az értéket tekintettem a finomhangolás (*fine-tuning*) előtti referencia-állapotnak.

A DEC és IDEC architektúrák tanítása során a célom az volt, hogy a neurális hálózat az autoenkóderes előtanítást követően iteratív módon olyan látens reprezentációt alakítson ki, amelyben a diagnosztikai csoportok jobban elkülönülnek.

Az eredmények összehasonlítása

A két modell teljesítményét az alábbi táblázatban foglaltam össze, ahol a végső, öt klaszterre történő leképezés utáni mutatókat tüntettem fel:

Baseline – DEC – IDEC comparison			
Modell	Ari	Purity	Clusters found
Baseline	0.0679	37.5%	5
DEC	0.0682	36.6%	5
IDEC	0.0811	38.1%	5


A kapott eredményekből egyértelmű különbség rajzolódott ki a két architektúra között:

- **DEC modell:** A tisztán klaszterezési hibára optimalizált DEC modell eredményei alulmúlták a várakozásaimat. A 36,6%-os tisztaság és a 0,0682-es ARI érték szinte teljesen megegyezett a K-Means baseline-nal. Ez arra utalt, hogy a dekódoló réteg elhagyása és a kizárólagos klaszterezési irányú optimalizáció miatt a hálózat olyan mértékben torzította a reprezentációt, hogy az elvesztette eredeti strukturális integritását.
- **IDEC modell:** Az IDEC architektúra ezzel szemben pozitív irányba mozdította a teljesítményt. A 0,0811-es ARI érték és a 38,1%-os tisztaság (Purity) egyaránt meghaladta a baseline eredményeit, bár nem sokkal

Értékelés és szakmai konklúzió

A kísérletsorozat egyik legfontosabb tanulsága, hogy az IDEC modell mérhetően jobban teljesített a DEC-nél. Ez a különbség megerősíti azt a hipotézist, hogy a rekonstrukciós hiba (*MSE Loss*) megtartása a finomhangolás során kritikus jelentőségű: az IDEC a klaszterezési célok mellett kényszerítette a hálózatot, hogy tartsa meg az EKG-beágyazások eredeti struktúráját.

Bár az ARI és a tisztasági mutatók növekedése a mélytanulós modellek esetén is visszafogott maradt (maximum 38,1%), a kísérlet rávilágított arra a tényre, hogy a MOMENT beágyazások eleve egy olyan nagy pontosságú, sűrített reprezentációt adnak, amelyen a klaszterezési hibák további csökkentése már csak minimális mértékben lehetséges. A mélytanulós architektúra alkalmazása tehát igazolta, hogy az orvosi adatokban lévő összefonódott mintázatok nem egy technikai hiba, hanem a klinikai valóság része: a betegségek közötti határvonalak a fiziológiai jelekben sem húzhatóak meg élesen, hanem folytonos átmenetet képeznek.



3.3. A legeredményesebb modellek összehasonlítása

A kutatás során alkalmazott felügyelet nélküli algoritmusok kiértékelése után szükségessé vált a két legeredményesebb – bár koncepcionálisan teljesen eltérő – megközelítés közvetlen összehasonlítása. A hagyományos, de fejlett gépi tanulási modellek közül a valószínűségi alapú **GMM** (Gaussian Mixture Model), míg a mélytanulási architektúrák közül a topológiát megőrző **IDEC** (Improved Deep Embedding Clustering) bizonyult a leghatékonyabbnak. Az objektív összehasonlíthatóság érdekében mindkét modellt a 2680 mintát tartalmazó, teljesen kiegyensúlyozott (*balanced*) adathalmazon vizsgáltam.

Metrikák és teljesítménybeli egyezések

A két modell metrikáinak egymás mellé állítása egy rendkívül érdekes, és a kutatás szempontjából meghatározó eredményt mutatott: a két algoritmus szinte hajszálpontosan ugyanazt a teljesítményszintet érte el.

- **Tisztasági mutató (Purity Accuracy):** A GMM és az IDEC egyaránt **38,1%-os** tisztasággal rendezte az adatpontokat az öt fő diagnosztikai klaszterbe.
- **Korrigált Rand-index (ARI):** A GMM **0,0835-ös** értéke csupán marginálisan, statisztikailag elhanyagolható mértékben múlta felül az IDEC **0,0811-es** eredményét.

Az a tény, hogy ez a két, egymástól gyökeresen eltérő optimalizálási stratégia pontosan ugyanabba a 38%-os teljesítménybeli üvegplafonba ütközött, a szakdolgozatom egyik legfontosabb felismerése. Ez empirikus bizonyítékot szolgáltat arra, hogy a klaszterezés további javításának gátja már nem az alkalmazott gépi tanulási vagy mélytanulási algoritmusok képességeiben található. A korlátot maguk a biológiai adatok jelentik: az EKG felvételeken alapuló orvosi diagnózisok a valóságban sem képeznek diszkrét, élesen elhatárolható halmazokat. A MOMENT beágyazások hűen tükrözik ezt a klinikai folytonosságot, amelyet a modellek – bármilyen fejlett matematikát is alkalmazzanak – nem tudnak szétszakítani.

4. Összefoglalás

Kutatásom során arra a komplex feladatra kerestem választ, hogy a legújabb, idősoros adatokra tervezett alapmodellek által generált mesterséges reprezentációk mennyire hatékonyan alkalmazhatók a klinikai EKG-diagnosztikában, felügyelet nélküli környezetben. A munka során végigjártam az adatelemzés teljes folyamatát a nyers többcsatornás jelek transzformációjától kezdve az alapvető geometriai algoritmusokon át egészen a fejlettebb mélytanulós és valószínűségi modellekig.

4.1. A *MOMENT* alapmodell alkalmazhatósága az EKG-diagnosztikában

A kísérleteim első legfontosabb mérföldköve az alapmodell által létrehozott 1024 dimenziós jellemzőtér validálása volt. A felügyelt tanulási tesztek egyértelműen bebizonyították, hogy a transzformátor-alapú architektúra sikeresen ki tudta nyerni a nyers idősorokból a releváns kardiológiai információkat, hiszen a modellek magas pontossággal képesek voltak azonosítani a különböző betegségtanokra.

Ugyanakkor rámutattam arra is, hogy ez a sűrű jellemzőtér önmagában, közvetlen felügyelet nélküli klaszterezésre rendkívül nehezen használható. A magas dimenziószám miatt a pontok közötti euklideszi távolságok elmosódnak, a térben nem alakulnak ki élesen elkülönülő formák. A *MOMENT* modell tehát egy kiváló minőségű, információban gazdag, de geometriai szempontból rendkívül összetett reprezentációt biztosít, amelynek a felügyelet nélküli kibogozásához egyszerű távolságmérések helyett célzott térbeli transzformációkra és fejlettebb struktúramodellezésre van szükség.

4.2. A felügyelet nélküli algoritmusok korlátai és a klinikai adatok természete

A kutatásom legnagyobb adatkutatói tanulságát a modellek osztály-kiegyensúlyozatlansággal szembeni viselkedésének elemzése adta. Kezdetben a naiv megközelítések a domináns egészséges osztály jelenléte miatt a tisztaság hamis illúzióját keltették. Amikor azonban ezt a statisztikai torzítást egy szigorú mintavételezési stratégiával megszüntettem, felszínre kerültek a modellek valós korlátai.

A kísérletek végén egy rendkívül izgalmas jelenséget azonosítottam: a legjobb hagyományos statisztikai modell (a valószínűségi megközelítés) és a legfejlettebb mélytanulós architektúra (amely tanítás közben aktívan alakította át a látens teret) hajszálpontosan ugyanabba a 38%-os tisztasági üvegplafonba ütközött.

Ez az eredmény vezetett a dolgozatom legfontosabb következtetéséhez. Ez a korlát nem az általam használt algoritmusok hiányosságaiból fakad, hanem magából a klinikai valóságból és a biológiai adatok természetéből. Az emberi szív elektromos működése és a különböző szívbetegségek nem diszkrét, éles határokkal elválasztható dobozokként léteznek. A normál EKG-k, a különböző vezetési zavarok és a strukturális elváltozások között folyamatosak az átmenetek, hatalmasak az átfedési zónák. Az alapmodell beágyazási tere hűen tükrözi ezt a biológiai folytonosságot, a felügyelet nélküli modellek pedig matematikailag igazolták, hogy

ezeket az összefonódott mintázatokat nem lehet és nem is szabad merev, mesterséges határokkal szétszakítani.

4.3. Jövőbeli kutatási irányok és fejlesztési lehetőségek

Bár a felügyelet nélküli eljárások elérték a természetes határaikat ezen a beágyazási téren, a dolgozatomban bemutatott pipeline szilárd alapot biztosít a jövőbeli kutatások számára. A továbblépésre négy fő irányt látok reálisnak:

- **Félig-felügyelt tanulás (Semi-supervised learning):** Mivel a teljesen felügyelt modellek jól teljesítettek, a tisztán felügyelet nélküli eljárások pedig a folytonosságot mutatták meg, a jövőben érdemes lenne olyan modelleket vizsgálni, amelyek minimális számú orvosi címke (részleges felügyelet) segítségével, rávezetik a mély klaszterező hálózatokat a helyes klinikai irányokra.
- **Új generációs alapmodellek tesztelése:** Az adattudomány rendkívül gyors fejlődése miatt érdemes lenne a MOMENT-en kívül más, alternatív idősoros alapmodellek reprezentációs képességeit is megvizsgálni ugyanezen a keretrendszeren.
- **Klinikai metaadatok integrálása:** Az EKG-jelek önmagukban hordozzák a szív dinamikáját, de a diagnózist az orvosi gyakorlatban is befolyásolja a páciens kora, neme vagy anamnézise. Ezen strukturált metaadatok és a mélybeágyazások kombinálása a látens térben egy új dimenziót nyithatna meg a klaszterek szeparációjában.
- **Alosztályok vizsgálata:** A kutatás távlati folytatásaként érdemes lenne a beágyazásokat nem csupán az öt klinikai főosztály, hanem a PTB-XL adathalmazban található sokkal több specifikus alosztály mentén is elemezni. A finomabb felbontású, diagnosztikai kategóriák modellezése lehetővé tenné a látens térben megbúvó mikro-struktúrák feltárását. Ez a megközelítés hozzájárulhatna ahhoz, hogy a felügyelet nélküli eljárások ne a nagy, összefüggő betegségfelhők globális átfedéseinek bukjanak el, hanem a specifikusabb morfológiai jegyek alapján magasabb osztályozási és klaszterezési pontosságot érjenek el.

Összességében a szakdolgozatommal sikerült bizonyítanom, hogy az idősoros alapmodellek és a mélytanulós klaszterezés kombinációja egy rendkívül erős eszköz a modern orvosi informatikában, amely képes feltárni és számszerűsíteni a klinikai diagnózisok mögött meghúzódó komplex, folytonos fiziológiai valóságot.

Irodalomjegyzék

- [1] P. Wagner és mtsai., "PTB-XL, a large publicly available electrocardiography dataset," *Scientific Data*, 2020. Elérhető: <https://www.nature.com/articles/s41597-020-0495-6>
- [2] M. Goswami és mtsai., "MOMENT: A Family of Open Time-series Foundation Models," *Proceedings of the 41st International Conference on Machine Learning*, 2024. Elérhető: <https://proceedings.mlr.press/v235/goswami24a.html>
- [3] A. Vaswani és mtsai., "Attention is all you need," *Advances in Neural Information Processing Systems*, 2017. Elérhető: <https://arxiv.org/abs/1706.03762>
- [4] L. McInnes és mtsai., "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction," *arXiv preprint arXiv:1802.03426*, 2018. Elérhető: <https://arxiv.org/abs/1802.03426>
- [5] J. MacQueen, "Some methods for classification and analysis of multivariate observations," *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*, 1967. Elérhető: <https://projecteuclid.org/ebooks/berkeley-symposium-on-mathematical-statistics-and-probability/Proceedings-of-the-Fifth-Berkeley-Symposium-on-Mathematical-Statistics-and-probability/Chapter/Some-methods-for-classification-and-analysis-of-multivariate-observations/bsmsp/1200512992>
- [6] M. Ester és mtsai., "A density-based algorithm for discovering clusters in large spatial databases with noise," *KDD*, 1996. Elérhető: <https://dl.acm.org/doi/10.5555/3001460.3001507>
- [7] R. J. Campello és mtsai., "Density-based clustering based on hierarchical density estimates," *Pacific-Asia conference on knowledge discovery and data mining*, 2013. Elérhető: https://link.springer.com/chapter/10.1007/978-3-642-37456-2_14
- [8] T. Akiba és mtsai., "Optuna: A next-generation hyperparameter optimization framework," *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, 2019. Elérhető: <https://dl.acm.org/doi/10.1145/3292500.3330701>
- [9] Scikit-learn Developers, "Silhouette Coefficient," *scikit-learn 1.4.2 documentation*. Elérhető: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html#sklearn.metrics.silhouette_score
- [10] Scikit-learn Developers, "Adjusted Rand index," *scikit-learn 1.4.2 documentation*. Elérhető: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.adjusted_rand_score.html#sklearn.metrics.adjusted_rand_score
- [11] Scikit-learn Developers, "Normalized Mutual Information," *scikit-learn 1.4.2 documentation*. Elérhető: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.normalized_mutual_info_score.html#sklearn.metrics.normalized_mutual_info_score
- [12] J. Xie és mtsai., "Unsupervised deep embedding for clustering analysis," *International conference on machine learning*, 2016. Elérhető: <https://proceedings.mlr.press/v48/xieb16.html>
- [13] X. Guo és mtsai., "Improved deep embedded clustering with local structure preservation," *IJCAI: proceedings of the conference*, 2017. Elérhető: <https://www.ijcai.org/Proceedings/2017/243>
- [14] Giricz Vince, "Multidimenzionális idősorok előfeldolgozása és osztályozása deep learning alapú megközelítésekkel," *GitHub repozitórium*, 2026. Elérhető: <https://github.com/Gvince04/Szakdolgozat/tree/main>
- [15] M. Goswami és mtsai., "MOMENT hivatalos forráskód," *GitHub repozitórium*, 2024. Elérhető: <https://github.com/moment-timeseries-foundation-model/moment>

[16] Anaconda Inc., "Conda – Package, dependency and environment management for any language," *Conda Documentation*. Elérhető: <https://docs.conda.io/en/latest/>

[17] Project Jupyter, "JupyterLab Documentation," *JupyterLab 4.1.x documentation*. Elérhető: <https://docs.jupyter.org/en/latest/>


Nyilatkozat

Alulírott Programtervező Informatikus szakos hallgató, kijelentem, hogy a dolgozatomat a Szegedi Tudományegyetem, Informatikai Intézet Szoftverfejlesztés Tanszékén készítettem, alapkú diploma megszerzése érdekében.

Kijelentem, hogy a dolgozatot más szakon korábban nem védtem meg, saját munkám eredménye, és csak a hivatkozott forrásokat (szakirodalom, eszközök, stb.) használtam fel.

Tudomásul veszem, hogy szakdolgozatomat / diplomamunkámat a Szegedi Tudományegyetem Diplomamunka Repozitóriumban tárolja.

Dátum: Kecskemét, 2026. május 22.



Aláírás

Köszönetnyilvánítás

Ezúton szeretném kifejezni hálámat és köszönetemet témavezetőmnek, **Dr. Jász Judit egyetemi adjunktusnak**, aki iránymutatásával, értékes szakmai tanácsaival és türelmével mindvégig támogatta a kutatómunkámat és a szakdolgozatom elkészítését. Szakmai iránymutatása nélkül ez a dolgozat nem jöhetett volna létre.

Ugyancsak szeretném megköszönni **családomnak, barátnőmnek és barátaimnak** azt a végtelen türelmet, biztatást és megértést, amellyel egyetemi tanulmányaimat és a dolgozat megírását végigkísérték. Támogatásuk nélkülözhetetlen háttérrel biztosított a sikeres munkához.